

修士論文

深層強化学習を用いたヒューマノイドロボットの 歩行動作に対する報酬関数の影響分析

Analysis of the effects of reward functions on the walking behavior
of a humanoid robot using deep reinforcement learning

2026 年 1 月 5 日 提出

指導教員 林原 靖男 教授

千葉工業大学大学院 先進工学研究科 未来ロボティクス専攻

24S1011 小川晴生

概要

深層強化学習を用いたヒューマノイドロボットの
歩行動作に対する報酬関数の影響分析

キーワード:

abstract

title

keywords:

目次

第 1 章	序論	1
1.1	背景	1
1.2	関連研究	3
1.3	目的	5
1.4	論文構成	5
第 2 章	要素技術	6
2.1	ニューラルネットワーク	6
2.2	強化学習	6
2.3	NVIDIA Isaac Lab	6
2.4	深層強化学習による歩行制御	7
2.5	報酬関数の設計	8
第 3 章	実験環境と方法	9
3.1	実験装置	9
3.2	エージェントと環境モデル	10
3.3	状態・行動空間	11
3.3.1	行動空間	11
3.3.2	状態空間	11
3.4	学習におけるランダム要素	12
3.5	報酬関数（報酬項）	12
第 4 章	実験条件と評価指標	14

目次	vi
4.1 実験方法	14
4.2 評価指標	14
4.3 評価指標に則り標準パラメータで学習した結果	15
第 5 章 実験	17
5.1 実験目的	17
5.2 実験環境	17
5.3 実験	17
5.4 実験結果	17
5.5 評価	17
5.6 考察	17
参考文献	18
付録	20
.1 Flat 環境	20
.1.1 track_lin_vel_xy_exp	20
.1.2 feet_air_time	32
.1.3 dof_pos_limits	32
.1.4 joint_deviation_hip	32
.1.5 lin_vel_z_l2	32
.1.6 dof_acc_l2	32
.1.7 dof_torques_l2	32
.1.8 feet_slide	32
謝辞	33

目次

1.1	Digit, Agility Robotics (source: [1])	2
1.2	Atlas, Boston Dynamics (source: [2])	2
1.3	Experimental results of the proposed method (source: [3])	3
1.4	Overview of the proposed gait-conditioned reinforcement learning method. (a) illustrates the policy network architecture with gait encoding, and (b) shows the dynamic reward composition using the Gait Mask (source: [4]).	4
1.5	STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion (source: [5])	5
2.1	Example	6
2.2	How NVIDIA Isaac Lab Works	7
2.3	Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning (source: [6])	7
3.1	Environments based on legged locomotion tasks	11
4.1	Walking behavior with standard parameters	15

表目次

3.1	Experimental Setup	9
3.2	Actuator Parameters of the Unitree G1 Robot Model	10
3.3	Actuator Parameters of the Unitree G1 Robot Model	10

第 1 章

序論

1.1 背景

近年，少子高齢化に伴う労働人口の減少が深刻化しており，人間に代わる作業の自動化や，災害現場などの危険な環境下での活動手段として，ヒューマノイドロボットへの期待が高まっている．これまでヒューマノイドロボットの歩行制御には，主に物理モデルに基づく制御手法が用いられてきた [7]．しかし近年では，複雑な環境への適応能力や，より高度な動作獲得の可能性から，深層強化学習（Deep Reinforcement Learning: DRL）を用いたアプローチ [8] が急速に発展している．DRL では，ロボット（エージェント）が環境と相互作用し，得られる「報酬」を最大化するように行動を学習する．この際，どのような行動に対して報酬を与えるかを定義する「報酬関数」の設計は，学習の成否や獲得される動作の質を決定づける重要な要素である．しかし，既存の研究動向を概観すると，学習アルゴリズムやネットワーク構造の提案に主眼が置かれる傾向があり，報酬関数の設計論に関する議論は十分になされていないのが現状である．多くの研究において，報酬関数内の各パラメータは，設計者の経験則や膨大な回数の試行錯誤によって決定されている．近年では大規模言語モデル（LLM）等を用いたパラメータ調整の自動化 [5] も試みられているが，最終的に「なぜそのパラメータ設定が良いのか」という因果関係や，各項が歩行性能や動作の質に与えるトレードオフについてはブラックボックス化している側面が否めない．



Fig. 1.1: Digit, Agility Robotics (source: [1])




Fig. 1.2: Atlas, Boston Dynamics (source: [2])

1.2 関連研究

Van Marum らは、ヒューマノイドロボットの立位および歩行制御において、実世界での性能を定量的に評価、比較するための低コストなベンチマーク手法を提案するとともに、報酬関数の設計を再考し、従来の規定的な報酬に代わる、制約を最小限に留めた報酬関数を構築した。コマンド追従性や外乱回復などの指標を用いた実験により、提案手法が外乱に対して堅牢な制御器の学習を可能にすることを示している。




Fig. 1.3: Experimental results of the proposed method (source: [3])

Peng らは、ヒューマノイドロボットが歩行、走行、ホッピングといった多様な歩容 (Gait) を単一のポリシーで実現するために、歩行周期の位相情報を用いた条件付き強化学習手法を提案している (図 1.4)。彼らは、学習の進捗に合わせてタスクの難易度を調整するマルチフェーズカリキュラムに加え、Gait Mask と呼ばれる報酬設計手法を導入した。これは、歩行サイクル中の特定の位相 (接地や足の振り出しなど) においてのみ特定の報酬項を有効化あるいは無効化する仕組みである。この動的な報酬設計により、静的な報酬関数では競合しがちな制約を適切に分離し、全方向へのロバストな移動動作の獲得に成功している。




Fig. 1.4: Overview of the proposed gait-conditioned reinforcement learning method. (a) illustrates the policy network architecture with gait encoding, and (b) shows the dynamic reward composition using the Gait Mask (source: [4]).

Wu らは、大規模言語モデル (LLM) を用いて報酬関数の設計から学習実行、フィードバックによる最適化までを全自動化するフレームワーク「STRIDE」を提案している (図 1.5)。STRIDE では、ロボットの身体構造 (URDF) とタスク記述を LLM に入力することで、Python 形式の報酬関数コードを生成する。さらに、シミュレーションから得られた学習結果 (歩行速度や失敗要因など) をテキスト情報として LLM にフィードバックし、報酬コードの修正と再学習を自律的に繰り返す。比較実験において、STRIDE は従来の手法 (EUREKA など) や人間が設計した報酬関数を上回るパフォーマンスを発揮し、多様な地形でのスプリント動作の獲得に成功している。




Fig. 1.5: STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion (source: [5])

1.3 目的

本研究では、深層強化学習を用いたヒューマノイドロボットの歩行動作獲得を対象とし、報酬関数の設計が歩行性能や動作に与える影響を明らかにすることを目的とする。具体的には、報酬関数を構成する各パラメータを複数の設定で変更しながら学習実験を行い、得られた制御則を複数の定量的な指標を用いて評価、分析する。これにより、各報酬項の役割やパラメータ間のトレードオフ関係について考察する。

1.4 論文構成

本論文の構成を述べる。本論文は、以下の全 0 章で構成されている。第 1 章では、本研究の背景や関連技術、目的を述べる。第 2 章では、本研究に用いた要素技術を述べる。第 3 章では、本研究に用いる学習環境について述べる。第 4 章では、本研究に用いる評価指標について述べる。第 5 章では、各学習モデルを評価指標で得られた結果について述べる。第 6 章では、実験やその結果に対する考察を述べる。第 7 章では、本研究の成果をまとめ、今後の展望について述べる。

第 2 章

要素技術

2.1 ニューラルネットワーク

ニューラルネットワークだけの節を作るのはもったいないため，深層強化学習の中で話した方がよいかもしれない



Fig. 2.1: Example

2.2 強化学習

2.3 NVIDIA Isaac Lab

NVIDIA Isaac Lab は，NVIDIA Omniverse プラットフォーム上に構築された，ロボット学習のための次世代シミュレーションフレームである．物理演算エンジン PhysX による高精

度な剛体シミュレーションと、GPU による超並列計算を活用することで、数千体のロボットを同時にシミュレーションすることが可能である。




Fig. 2.2: How NVIDIA Isaac Lab Works

2.4 深層強化学習による歩行制御




Fig. 2.3: Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning (source: [6])

2.5 報酬関数の設計

第 3 章

実験環境と方法

本章では，報酬関数の変化が歩行動作へ与える影響を調査するために行う実験について述べる．まず，学習に使用したシミュレータや実験を行う環境モデル，エージェントについて述べる．なお，本実験では NVIDIA Isaac Lab で標準提供されている Unitree G1 の学習環境（locomotion）を用いる．次に，状態，行動空間や報酬関数について述べる．

3.1 実験装置

本実験の環境を表に示す．

Table 3.1: Experimental Setup

OS	Ubuntu 22.04
Simulator	NVIDIA Isaac Sim
Framework	NVIDIA Isaac Lab
CPU	Intel [®] Core™ i7-14700
GPU	NVIDIA GeForce RTX 4090 SUPER
RAM	32 GB
Storage	2.0 TB

Table 3.2: Actuator Parameters of the Unitree G1 Robot Model


Joint Name	Max Trq. [Nm]	Max Vel. [rad/s]	Stiffness (K_p)	Damping (K_d)
Hip (Yaw, Roll)	300.0	23.0	150.0	5.0
Hip (Pitch), Knee, Torso	300.0	23.0	200.0	5.0
Ankle (Pitch, Roll)	20.0	9.0	20.0	2.0
Arms (Shoulder, Elbow, Wrist)	300.0	23.0	40.0	10.0

Table 3.3: Actuator Parameters of the Unitree G1 Robot Model

Joint Name	Max Torque [Nm]	Max Velocity [rad/s]	Stiffness (K_p) [Nm/rad]	Damping (K_d) [Nms/rad]
Hip (Yaw, Roll)	300.0	23.0	150.0	5.0
Hip (Pitch), Knee, Torso	300.0	23.0	200.0	5.0
Ankle (Pitch, Roll)	20.0	9.0	20.0	2.0
Arms (Shoulder, Elbow, Wrist)	300.0	23.0	40.0	10.0

3.2 エージェントと環境モデル

本研究では、エージェントとして NVIDIA Isaac Lab にて標準提供されている Unitree G1 のロボットモデルを使用する。また、実験を行う環境モデルについては、3.1 に示すように、平地環境と不整地環境があり、不整地環境はピラミッド上の階段、スロープ、凹凸の地面がある。



(a) Track a velocity command on flat terrain with the Unitree G1



(b) Track a velocity command on rough terrain with the Unitree G1

Fig. 3.1: Environments based on legged locomotion tasks

3.3 状態・行動空間

3.3.1 行動空間

行動空間は、ロボットの各関節に対する目標角度司令で構成される連続空間である。制御周期ごとに、ポリシーネットワークから出力された行動は、初期姿勢からの相対的な変位として解釈され、スケール係数 (0.5) が乗じられた後、デフォルトの関節角度に加算される。最終的なトルク司令は、P ゲイン (剛性) K_p および D ゲイン (減衰) K_d を用いた PD 制御則により算出される。

$$\tau = K_p(q_{target} - q) - K_d\dot{q} \quad (3.1)$$

ここで、 q および $\dot{q}$ は現在の関節角度および角速度である。

3.3.2 状態空間

表を作る

3.4 学習におけるランダム要素

3.5 報酬関数（報酬項）

本研究では、NVIDIA Isaac Lab, locomotion（二足歩行ロボットが歩行動作＝タスク）を用いる。本研究における報酬関数は以下の通りである。

- $R_{termination_penalty}$: ロボットが転倒などの致命的な失敗によりエピソードを終了した場合に、学習がそのような状態を避けるよう促すためである。これは、エージェントに対してこの状態に陥ると大きな大きな不利益があることを学習させ、転倒を避ける動作を促す。

$$r_{term} = w_{term} \cdot \mathbb{I}_{terminated} \quad (3.2)$$

ここで、 $w_{term} = -200.0$ はペナルティの重み係数であり、 $\mathbb{I}_{terminated}$ はエピソードの異常終了を判定する指示関数である。本モデルにおいて、この項はロボットの胴体（torso.link）が地面に接触した瞬間に適用され、エージェントに対して転倒を回避する強力なバイアスを与える役割を果たす。

- $R_{track_lin_vel_xy_exp}$ （XY 線形速度追従）：エージェントのヨー軸（向いている方向）を基準とした XY 平面での線形速度が、目標速度にどれくらい近いか評価し、誤差が小さいほど高い報酬を与える。誤差の評価には指数カーネル（共分散）が使用される。

$$r_{track_lin} = \exp\left(-\frac{\|\mathbf{v}_{xy}^{cmd} - \mathbf{v}_{xy}^{base_yaw}\|_2^2}{\sigma^2}\right)$$

- $R_{track_ang_vel_z_exp}$ （Z 軸角速度追従）：エージェントの目標角速度にどれだけ近いかを評価する。

$$r_{track_ang} = \exp\left(-\frac{(\omega_z^{cmd} - \omega_z^{world})^2}{\sigma^2}\right)$$

- $R_{feet_air_time}$ （足の滞空時間）：足が地面から離れている時間（滞空時間）が一定の閾値（ T_{thresh} ）を超えた場合に報酬を与える。これにより、足を地面に擦るのではなく、持ち上げて歩行する動作を促す。

$$r_{air_time} = \max(0, \min(T_{air,L}, T_{air,R}) - T_{thresh})$$

- R_{feet_slide} （足の滑りペナルティ）：足が地面に接地していると判定されている間に、

その足がワールド座標系の XY 方向に速度を持つ（＝滑っている）ことに対してペナルティを与える．

$$r_{\text{slide}} = \sum_{f \in \{\text{left}, \text{right}\}} \|\mathbf{v}_{xy}^{\text{foot}, f}\|_2 \cdot \mathbb{I}(F_{\text{contact}, f} > F_{\text{thresh}})$$

- $R_{\text{flat_orientation_l2}}$ （水平姿勢維持ペナルティ）：エージェントの胴体が水平から傾くことに対してペナルティを与える．

$$r_{\text{orientation}} = \|\mathbf{g}_{\text{proj}, xy}^{\text{base}}\|_2^2 = (g_x^{\text{base}})^2 + (g_y^{\text{base}})^2$$

- $R_{\text{dof_pos_limits}}$ （関節可動域ペナルティ）：関節角度が設定された可動域の上限または下限に近づくことに対してペナルティを与える．

- $R_{\text{joint_deviation_...}}$ （デフォルト姿勢からの逸脱ペナルティ）：

- $R_{\text{action_rate_l2}}$ ：

$$r_{\text{action_rate}} = \|\mathbf{a}_t - \mathbf{a}_{t-1}\|_2^2$$

- $R_{\text{dof_acc_l2}}$ ：

- $R_{\text{dof_torques_l2}}$ ：

$$r_{\text{torque}} = \|\boldsymbol{\tau}\|_2^2 = \sum_{j \in \text{joints}} \tau_j^2$$

第 4 章

実験条件と評価指標

本章では，報酬関数の変化が歩行動作へ与える影響を調査するために行う実験条件と評価指標について述べる．

4.1 実験方法

第 3 章の 0 節で，報酬関数とそのパラメータについて述べた．本研究では，それらをパラメータを変化させる基準として実験を行う．以下に調査の対象とする報酬関数とその比較をするパラメータを示す．

4.2 評価指標

以下の論文を参考に，各報酬関数のパラメータを変更させて実験を行い，歩行動作に与える影響を評価する．以下は，評価指標の一覧である．

- 各関節のトルク，速度
- 歩行速度前進 $1[m/s]$ に対する追従率
- 床反力
- 胴体の姿勢のズレ
- 左右の歩幅
- 重心と左右の足上げ高さ

- CoT (Cost of Transport)

4.3 評価指標に則り標準パラメータで学習した結果














Fig. 4.1: Walking behavior with standard parameters





第 5 章

実験

5.1 実験目的

まず、各報酬関数が要求されている機能が行われているかの確認

5.2 実験環境

5.3 実験

NVIDIA Isaac Lab に提供されている Unitree G1, locomotion の報酬関数を基準として,

etc...

実験分析方法

5.4 実験結果

本実験で腕や指を対象としない理由

5.5 評価

5.6 考察

etc...

参考文献

- [1] Agility Robotics. Agility robotics. <https://www.agilityrobotics.com/>, 2026. (Accessed on 01/03/2026).
- [2] Boston Dynamics. Atlas — boston dynamics. <https://bostondynamics.com/atlas/>, 2026. (Accessed on 01/03/2026).
- [3] Bart van Marum, Aayam Shrestha, Helei Duan, Pranay Dugar, Jeremy Dao, and Alan Fern. Revisiting reward design and evaluation for robust humanoid standing and walking, 2024. IROS 2024.
- [4] Tianhu Peng, Lingfan Bao, and Chengxu Zhou. Gait-conditioned reinforcement learning with multi-phase curriculum for humanoid locomotion, 2025.
- [5] Zhenwei Wu, Jinxiong Lu, Yuxiao Chen, Yunxin Liu, Yueting Zhuang, and Luhui Hu. Stride: Automating reward design, deep reinforcement learning training and feedback optimization in humanoid robotics locomotion, 2025.
- [6] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning, 2021.
- [7] Zhaoyuan Gu, Junheng Li, Wenlan Shen, Wenhao Yu, Zhaoming Xie, Stephen McCrory, Xianyi Cheng, Abdulaziz Shamsah, Robert Griffin, C. Karen Liu, Abderrahmane Kheddar, Xue Bin Peng, Yuke Zhu, Guanya Shi, Quan Nguyen, Gordon Cheng, Huijun Gao, and Ye Zhao. Humanoid locomotion and manipulation: Current progress and challenges in control, planning, and learning, 2025.
- [8] Lingfan Bao, Josephine N. Humphreys, Tianhu Peng, and Chengxu Zhou. Deep reinforcement learning for bipedal locomotion: A brief survey, 2024.
- [9] The robocup japanese regional committee — ロボカップとは. <https://www.robocup.>




or.jp/robocup/. (Accessed on 12/29/2022).










付録







本付録では、本論文の実験において得られた歩行動作の時系列データを記録したグラフを記載する。他は載せきれていません↓にデータはあります https://drive.google.com/drive/folders/1cLqWSd5YyQSVBBJg8vCJhD_Xbf23-j23?usp=sharing






.1 Flat 環境










.1.1 track_lin_vel_xy_exp


































































- .1.2 feet_air_time
- .1.3 dof_pos_limits
- .1.4 joint_deviation_hip
- .1.5 lin_vel_z_l2
- .1.6 dof_acc_l2
- .1.7 dof_torques_l2
- .1.8 feet_slide

謝辞

本研究を進めるにあたり， 1 年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします。