

修士論文

深層強化学習を用いたヒューマノイドロボットの 歩行動作に対する報酬関数の影響分析

Analysis of the effects of reward functions on the walking behavior
of a humanoid robot using deep reinforcement learning

2026 年 1 月 7 日 提出

指導教員 林原 靖男 教授

千葉工業大学大学院 先進工学研究科 未来ロボティクス専攻

24S1011 小川晴生

概要

深層強化学習を用いたヒューマノイドロボットの
歩行動作に対する報酬関数の影響分析

キーワード:

abstract

title

keywords:

目次

第 1 章	序論	1
1.1	背景	1
1.2	関連研究	3
1.3	目的	5
1.4	論文構成	5
第 2 章	要素技術	6
2.1	ニューラルネットワーク	6
2.2	強化学習	6
2.3	NVIDIA Isaac Lab	6
2.4	深層強化学習による歩行制御	7
2.5	報酬関数の設計	8
第 3 章	実験環境と方法	9
3.1	実験装置	9
3.2	エージェントと環境モデル	10
3.3	状態・行動空間	11
3.3.1	行動空間	11
3.3.2	状態空間	11
3.4	学習におけるランダム要素	12
3.5	報酬関数	12
第 4 章	実験条件と評価指標	15

目次	vi
4.1 実験方法	15
4.2 評価指標	16
4.3 標準パラメータによる学習結果	16
第 5 章 実験結果と考察	19
5.1 あ	19
5.2 考察	19
参考文献	20
付録	23
.1 Flat 環境	23
.1.1 track_lin_vel_xy_exp	23
.1.2 feet_air_time	35
.1.3 dof_pos_limits	35
.1.4 joint_deviation_hip	35
.1.5 lin_vel_z_l2	35
.1.6 dof_acc_l2	35
.1.7 dof_torques_l2	35
.1.8 feet_slide	35
謝辞	36

目次

1.1	Digit, Agility Robotics (source: [1])	2
1.2	Atlas, Boston Dynamics (source: [2])	2
1.3	Experimental results of the proposed method (source: [3])	3
1.4	Overview of the proposed gait-conditioned reinforcement learning method. (a) illustrates the policy network architecture with gait encoding, and (b) shows the dynamic reward composition using the Gait Mask (source: [4]).	4
1.5	STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion (source: [5])	5
2.1	Example	6
2.2	How NVIDIA Isaac Lab Works	7
2.3	Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning (source: [6])	7
3.1	Environments based on legged locomotion tasks	11
4.1	Walking behavior with standard parameters	16

表目次

3.1	Experimental Setup	9
3.2	Actuator Parameters of the Unitree G1 Robot Model	10
3.3	Actuator Parameters of the Unitree G1 Robot Model	10
3.4	Reward Function Parameters for the Unitree G1 Robot in Flat Terrain .	14

第 1 章

序論

1.1 背景

近年、少子高齢化に伴う労働人口の減少が深刻化しており、人間に代わる作業の自動化や、災害現場などの危険な環境下での活動手段として、ヒューマノイドロボットへの期待が高まっている。これまでヒューマノイドロボットの歩行制御には、主に物理モデルに基づく制御手法が用いられてきた [7]。しかし近年では、複雑な環境への適応能力や、より高度な動作獲得の可能性から、深層強化学習 (Deep Reinforcement Learning: DRL) を用いたアプローチ [8] が急速に発展している。DRL では、ロボット (エージェント) が環境と相互作用し、得られる「報酬」を最大化するように行動を学習する。この際、どのような行動に対して報酬を与えるかを定義する「報酬関数」の設計は、学習の成否や獲得される動作の質を決定づける重要な要素である。しかし、既存の研究動向を概観すると、学習アルゴリズムやネットワーク構造の提案に主眼が置かれる傾向があり、報酬関数の設計論に関する議論は十分になされていないのが現状である。多くの研究において、報酬関数内の各パラメータは、設計者の経験則や膨大な回数の試行錯誤によって決定されている。近年では大規模言語モデル (LLM) 等を用いたパラメータ調整の自動化 [5] も試みられているが、最終的に「なぜそのパラメータ設定が良いのか」という因果関係や、各項が歩行性能や動作の質に与えるトレードオフについてはブラックボックス化している側面が否めない。



Fig. 1.1: Digit, Agility Robotics (source: [1])




Fig. 1.2: Atlas, Boston Dynamics (source: [2])

1.2 関連研究

Van Marum らは、ヒューマノイドロボットの立位および歩行制御において、実世界での性能を定量的に評価、比較するための低コストなベンチマーク手法を提案するとともに、報酬関数の設計を再考し、従来の規定的な報酬に代わる、制約を最小限に留めた報酬関数を構築した。コマンド追従性や外乱回復などの指標を用いた実験により、提案手法が外乱に対して堅牢な制御器の学習を可能にすることを示している。




Fig. 1.3: Experimental results of the proposed method (source: [3])

Peng らは、ヒューマノイドロボットが歩行、走行、ホッピングといった多様な歩容 (Gait) を単一のポリシーで実現するために、歩行周期の位相情報を用いた条件付き強化学習手法を提案している (図 1.4)。彼らは、学習の進度に合わせてタスクの難易度を調整するマルチフェーズカリキュラムに加え、Gait Mask と呼ばれる報酬設計手法を導入した。これは、歩行サイクル中の特定の位相 (接地や足の振り出しなど) においてのみ特定の報酬項を有効化あるいは無効化する仕組みである。この動的な報酬設計により、静的な報酬関数では競合しがちな制約を適切に分離し、全方向へのロバストな移動動作の獲得に成功している。




Fig. 1.4: Overview of the proposed gait-conditioned reinforcement learning method. (a) illustrates the policy network architecture with gait encoding, and (b) shows the dynamic reward composition using the Gait Mask (source: [4]).

Wu らは、大規模言語モデル (LLM) を用いて報酬関数の設計から学習実行、フィードバックによる最適化までを全自動化するフレームワーク「STRIDE」を提案している (図 1.5)。STRIDE では、ロボットの身体構造 (URDF) とタスク記述を LLM に入力することで、Python 形式の報酬関数コードを生成する。さらに、シミュレーションから得られた学習結果 (歩行速度や失敗要因など) をテキスト情報として LLM にフィードバックし、報酬コードの修正と再学習を自律的に繰り返す。比較実験において、STRIDE は従来の手法 (EUREKA など) や人間が設計した報酬関数を上回るパフォーマンスを発揮し、多様な地形でのスプリント動作の獲得に成功している。




Fig. 1.5: STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion (source: [5])

1.3 目的

本研究では、深層強化学習を用いたヒューマノイドロボットの歩行動作獲得を対象とし、報酬関数の設計が歩行性能や動作に与える影響を明らかにすることを目的とする。具体的には、報酬関数を構成する各パラメータを複数の設定で変更しながら学習実験を行い、得られた制御則を複数の定量的な指標を用いて評価、分析する。これにより、各報酬項の役割やパラメータ間のトレードオフ関係について考察する。

1.4 論文構成

本論文の構成を述べる。本論文は、以下の全 0 章で構成されている。第 1 章では、本研究の背景や関連技術、目的を述べる。第 2 章では、本研究に用いた要素技術を述べる。第 3 章では、本研究に用いる学習環境について述べる。第 4 章では、本研究に用いる評価指標について述べる。第 5 章では、各学習モデルを評価指標で得られた結果について述べる。第 6 章では、実験やその結果に対する考察を述べる。第 7 章では、本研究の成果をまとめ、今後の展望について述べる。

第 2 章

要素技術

2.1 ニューラルネットワーク

ニューラルネットワークだけの節を作るのはもったいないため，深層強化学習の中で話した方がよいかもしれない



Fig. 2.1: Example

2.2 強化学習

2.3 NVIDIA Isaac Lab

NVIDIA Isaac Lab は，NVIDIA Omniverse プラットフォーム上に構築された，ロボット学習のための次世代シミュレーションフレームである．物理演算エンジン PhysX による高精

度な剛体シミュレーションと、GPU による超並列計算を活用することで、数千体のロボットを同時にシミュレーションすることが可能である。




Fig. 2.2: How NVIDIA Isaac Lab Works

2.4 深層強化学習による歩行制御




Fig. 2.3: Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning (source: [6])

2.5 報酬関数の設計

深層強化学習における報酬関数は、エージェントに望ましい挙動を学習させるための重要な要素である。指数関数カーネルを用いた報酬関数

第 3 章

実験環境と方法

本章では，報酬関数の変化が歩行動作へ与える影響を調査するために行う実験について述べる．まず，学習に使用したシミュレータや実験を行う環境モデル，エージェントについて述べる．なお，本実験では NVIDIA Isaac Lab[9] で標準提供されている Unitree G1 の学習環境 (locomotion) を用いる．次に，状態，行動空間や報酬関数について述べる．

3.1 実験装置

本実験の環境を表に示す．

Table 3.1: Experimental Setup

OS	Ubuntu 22.04
Simulator	NVIDIA Isaac Sim
Framework	NVIDIA Isaac Lab
CPU	Intel [®] Core™ i7-14700
GPU	NVIDIA GeForce RTX 4090 SUPER
RAM	32 GB
Storage	2.0 TB

初期姿勢においては，ロボットのベース（骨盤）の高さは 0.74 [m] に設定されている．また，ロボットの初期の関節角度は，直立姿勢を基準に定義されており，3.1a および 3.1b に示

Table 3.2: Actuator Parameters of the Unitree G1 Robot Model

Joint Name	Max Trq. [Nm]	Max Vel. [rad/s]	Stiffness (K_p)	Damping (K_d)
Hip (Yaw, Roll)	300.0	23.0	150.0	5.0
Hip (Pitch), Knee, Torso	300.0	23.0	200.0	5.0
Ankle (Pitch, Roll)	20.0	9.0	20.0	2.0
Arms (Shoulder, Elbow, Wrist)	300.0	23.0	40.0	10.0


Table 3.3: Actuator Parameters of the Unitree G1 Robot Model

Joint Name	Max Torque [Nm]	Max Velocity [rad/s]	Stiffness (K_p) [Nm/rad]	Damping (K_d) [Nms/rad]
Hip (Yaw, Roll)	300.0	23.0	150.0	5.0
Hip (Pitch), Knee, Torso	300.0	23.0	200.0	5.0
Ankle (Pitch, Roll)	20.0	9.0	20.0	2.0
Arms (Shoulder, Elbow, Wrist)	300.0	23.0	40.0	10.0

すように, Hip Pitch 関節は-0.20 [rad], Knee 関節は 0.42 [rad], Ankle Pitch 関節は-0.23 [rad] に設定されている.

3.2 エージェントと環境モデル

本研究では, エージェントとして NVIDIA Isaac Lab にて標準提供されている Unitree G1 のロボットモデルを使用する. また, 実験を行う環境モデルについては, 3.1 に示すように, 平地環境と不整地環境があり, 不整地環境はピラミッド上の階段, スロープ, 凹凸の地面がある.



(a) Track a velocity command on flat terrain with the Unitree G1



(b) Track a velocity command on rough terrain with the Unitree G1

Fig. 3.1: Environments based on legged locomotion tasks

3.3 状態・行動空間

強化学習におけるマルコフ決定過程 (MDP) は、状態空間 $\mathcal{S}$ 、行動空間 $\mathcal{A}$ 、遷移確率 P 、報酬関数 R 、割引率 γ の5つの要素から構成される。

3.3.1 行動空間

行動空間は、ロボットの各関節に対する目標角度司令で構成される連続空間である。制御周期ごとに、ポリシーネットワークから出力された行動は、初期姿勢からの相対的な変位として解釈され、スケール係数 (0.5) が乗じられた後、デフォルトの関節角度に加算される。最終的なトルク司令は、P ゲイン (剛性) K_p および D ゲイン (減衰) K_d を用いた PD 制御則により算出される。

$$\tau = K_p(q_{target} - q) - K_d\dot{q} \quad (3.1)$$

ここで、 q および $\dot{q}$ は現在の関節角度および角速度である。

3.3.2 状態空間

表を作る

3.4 学習におけるランダム要素

3.5 報酬関数

本研究では、目標速度への追従を目的とした正の報酬と、エネルギー効率や安定性を阻害する動作に対する負の報酬の加重和として、以下の報酬 r_t を定義した。

$$r_t = \sum_i \omega_i \cdot r_{i,t} \quad (3.2)$$

ここで、 ω_i は各報酬項の重み係数、 $r_{i,t}$ は時刻 t における各報酬項の値を示す。

- **Termination penalty**(終了ペナルティ)：エピソードが早期に終了した場合に与えられる大きな負の報酬である。これにより、エージェントは可能な限り転倒を避ける動作を促す。

$$r_{\text{term}} = \begin{cases} -200.0 & \text{if terminated} \\ 0 & \text{otherwise} \end{cases} \quad (3.3)$$

- **Track Lin Vel XY**：ロボット座標系における XY 平面の並進速度 v_{xy} と目標速度 $v_{\text{cmd},xy}$ の誤差に基づく。

$$r_{\text{lin_vel}} = \exp\left(-\frac{\|\mathbf{v}_{\text{cmd},xy} - \mathbf{v}_{xy}\|^2}{\sigma_{\text{lin}}^2}\right) \quad (3.4)$$

ここで、 $\sigma_{\text{lin}} = 0.5$ である。

- **Track Ang Vel Z**：ワールド座標系における Z 軸周りの ω_z と目標角速度 $\omega_{\text{cmd},z}$ の誤差に基づく。

$$r_{\text{ang_vel}} = \exp\left(-\frac{(\omega_{\text{cmd},z} - \omega_z)^2}{\sigma_{\text{ang}}^2}\right) \quad (3.5)$$

ここで、 $\sigma_{\text{ang}} = 0.5$ である。

- **Feet Air Time**(遊脚時間報酬)：二足歩行ロボット特有の交互な足運びを学習するため、片足支持状態における遊脚時間を報酬として与える。

$$r_{\text{air_time}} = \sum_{\text{foot}} \mathbb{I}_{\text{single_stance}} \cdot \min(t_{\text{air, foot}}, \theta_{\text{threshold}}) \quad (3.6)$$

ここで、 $t_{\text{air, foot}}$ は各足が滞空している時間、 $\theta_{\text{threshold}} = 0.4[s]$ は上限閾値である。

- **Lin Vel Z L2**：歩行中の上下動を抑制する.

$$r_{\text{lin_vel_z}} = -v_z^2 \quad (3.7)$$

- **Action Rate L2**：急激な制御入力の変化を抑える.

$$r_{\text{action_rate}} = -\|\mathbf{a}_t - \mathbf{a}_{t-1}\|^2 \quad (3.8)$$

- **DOF Acc L2**：関節加速度 $\ddot{\mathbf{q}}$ の大きさを抑制する.

$$r_{\text{dof_acc}} = -\|\ddot{\mathbf{q}}\|^2 \quad (3.9)$$

Hip, Knee に対して適用される.

- **DOF Torques L2**：関節トルク $\boldsymbol{\tau}$ の大きさを抑制する.

$$r_{\text{dof_torques}} = -\|\boldsymbol{\tau}\|^2 \quad (3.10)$$

Flat 環境では, Hip, Knee, Rough 環境では Hip, Knee, Ankle に対して適用される.

- **Feet Slide**：接地している足の水平速度 $v_{\text{foot},xy}$ に対するペナルティを与え, 地面に滑ることを防ぐ.

$$r_{\text{slide}} = -\sum_{\text{foot}} \mathbb{I}_{\text{contact}} \cdot \|\mathbf{v}_{\text{foot},xy}\| \quad (3.11)$$

- **Joint deviation(hip)**：特定の関節が, 初期姿勢から大きく逸脱することを防ぎ, 不自然な脚の開閉を抑制する.

$$r_{\text{joint_dev}} = -\sum_{j \in \mathcal{J}_{\text{target}}} |q_j - q_j^{\text{default}}| \quad (3.12)$$

- **Flat orientation**：ロボットの体幹 (Base Link) が地面に対して水平であることを促す.

$$r_{\text{flat_orient}} = -\|\mathbf{g}_{xy}^{\text{robot}}\|^2 \quad (3.13)$$

- **DOF Joint limits**(関節可動域ペナルティ)：各関節が可動域限界に近づきすぎることを防ぐ.

$$r_{\text{limits}} = -\sum_j (\max(0, q_j - q_j^{\text{max}} + \epsilon) + \max(0, q_j^{\text{min}} - q_j + \epsilon)) \quad (3.14)$$

Ankle に対して適用される.

また, $\mathbf{v}_{\text{cmd},xy}$ は目標並進速度, $\mathbf{v}_{xy}$ は現在の並進速度, $\omega_{\text{cmd},z}$ は目標旋回角速度, ω_z は現在の旋回角速度, $\sigma_{\text{lin}}, \sigma_{\text{ang}}$ はカーネル幅を表すスケーリングパラメータである. また, $\mathbf{a}_t$ は時刻 t における行動 (目標関節角度変位), $\ddot{\mathbf{q}}$ は関節角加速度, $\boldsymbol{\tau}$ は関節トルクを表す.

Table 3.4: Reward Function Parameters for the Unitree G1 Robot in Flat Terrain

Reward term	Weight(Flat)	Weight(Rough)
Track Lin Vel XY	1.0	1.0
Track Ang Vel Z	1.0	2.0
Feet Air Time	0.75	0.25
Lin Vel Z L2	-0.2	0.0
Action Rate L2	-0.005	-0.005
DOF Acc L2	-1.0×10^{-7}	-1.25×10^{-7}
DOF Torques L2	-2.0×10^{-6}	-1.5×10^{-7}
DOF Joint Limits	-1.0	-1.0
Feet Slide	-0.1	-0.1
Joint deviation(hip)	-0.1	-0.1
Flat orientation	-1.0	-1.0
Termination penalty	-200	-0.1

後でいらなかったら消す Flat 環境では, Z 軸方向の速度抑制 (Lin Vel Z L2) やトルク抑制 (DOF Torques L2) の重みが大きく設定されており, 無駄な上下動や過度な力の発揮を抑えた, 静的で安定した歩行の獲得を重視していることがわかる. 一方, Rough 環境では旋回速度追従 (Track Ang Vel Z) の重みが強化されているほか, 関節加速度やトルクに対するペナルティが緩和されており, 外乱や不整地に対応するためのダイナミックな動作を許容する設計となっている.

第 4 章

実験条件と評価指標

本章では，報酬関数の変化が歩行動作へ与える影響を調査するために行う実験条件と評価指標について述べる．

4.1 実験方法

本研究では，第 3 章で定義した報酬関数を構成する各項が，ヒューマノイドロボットの歩行動作獲得にどのような影響を与えるかを調査する．報酬関数に含まれる各項の重み係数 ω_i は，学習される動作の特性を決定づける重要なハイパーパラメータである．

本実験では，Table 3.4 に示した標準のパラメータ設定を基準とし，調査対象とする特定の報酬項の重みのみを個別に変化させながら学習を行うことで，その項が歩行挙動に与える影響を分離して評価する．調査対象とする報酬項およびそのパラメータ（重み）は以下の通りである．

- Track Lin Vel XY ：目標並進速度への追従 [0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 5.0]
- Feet Air Time ：遊脚時間の確保 [0.0, 0.1, 0.2, 0.4, 0.6, 0.8, 1.0]
- DOF Joint Limits ：関節可動域制限の遵守 [0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]
- Joint deviation(hip)：股関節の初期位置からの逸脱抑制
- Lin Vel Z L2 ：重心上下動（Z 軸速度）の抑制 [0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]
- DOF Acc L2 ：関節加速度の抑制 []
- DOF Torques L2 ：トルク消費の抑制 []
- Feet Slide ：接地時の滑り抑制 [0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]

- Flat orientation : ベースリンクの水平維持 [0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]

4.2 評価指標

以下の論文を参考に、各報酬関数のパラメータを変更させて実験を行い、歩行動作に与える影響を評価する。以下は、評価指標の一覧である。

- 各関節のトルク、速度
- 歩行速度前進 $1[m/s]$ に対する追従率
- 床反力
- 胴体の姿勢のズレ
- 左右の歩幅
- 重心と左右の足上げ高さ
- CoT (Cost of Transport)

4.3 標準パラメータによる学習結果

4.2 節の評価指標に基づき、まず第3章 Table 3.4 で示した標準パラメータを用いて学習を行った結果について述べる。標準パラメータを用いた学習では、ロボットは転倒することなく歩行を獲得した。Fig. 4.1 に、学習済みポリシーを用いた評価時の歩行動作の様子および各センサーデータの時系列波形を示す。











Fig. 4.1: Walking behavior with standard parameters





第 5 章

実験結果と考察

本章では，付録にある評価指標を用いた実験結果をもとに，各報酬関数の影響分析を行う．

5.1 あ

5.2 考察

etc...

参考文献

- [1] Agility Robotics. Agility robotics. <https://www.agilityrobotics.com/>, 2026. (Accessed on 01/03/2026).
- [2] Boston Dynamics. Atlas — boston dynamics. <https://bostondynamics.com/atlas/>, 2026. (Accessed on 01/03/2026).
- [3] Bart van Marum, Aayam Shrestha, Helei Duan, Pranay Dugar, Jeremy Dao, and Alan Fern. Revisiting reward design and evaluation for robust humanoid standing and walking, 2024. IROS 2024.
- [4] Tianhu Peng, Lingfan Bao, and Chengxu Zhou. Gait-conditioned reinforcement learning with multi-phase curriculum for humanoid locomotion, 2025.
- [5] Zhenwei Wu, Jinxiong Lu, Yuxiao Chen, Yunxin Liu, Yueting Zhuang, and Luhui Hu. Stride: Automating reward design, deep reinforcement learning training and feedback optimization in humanoid robotics locomotion, 2025.
- [6] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning, 2021.
- [7] Zhaoyuan Gu, Junheng Li, Wenlan Shen, Wenhao Yu, Zhaoming Xie, Stephen McCrory, Xianyi Cheng, Abdulaziz Shamsah, Robert Griffin, C. Karen Liu, Abderahmane Kheddar, Xue Bin Peng, Yuke Zhu, Guanya Shi, Quan Nguyen, Gordon Cheng, Huijun Gao, and Ye Zhao. Humanoid locomotion and manipulation: Current progress and challenges in control, planning, and learning, 2025.
- [8] Lingfan Bao, Josephine N. Humphreys, Tianhu Peng, and Chengxu Zhou. Deep reinforcement learning for bipedal locomotion: A brief survey, 2024.
- [9] Mayank Mittal and Pascal Roth and James Tigue and Antoine Richard and Octi

Zhang and Peter Du and Antonio Serrano-Muñoz and Xinjie Yao and René Zurbrügg and Nikita Rudin and Lukasz Wawrzyniak and Milad Rakhsha and Alain Denzler and Eric Heiden and Ales Borovicka and Ossama Ahmed and Iretiayo Akinola and Abrar Anwar and Mark T. Carlson and Ji Yuan Feng and Animesh Garg and Renato Gasoto and Lionel Gulich and Yijie Guo and M. Gussert and Alex Hansen and Mihir Kulkarni and Chenran Li and Wei Liu and Viktor Makoviychuk and Grzegorz Malczyk and Hammad Mazhar and Masoud Moghani and Adithyavairavan Murali and Michael Noseworthy and Alexander Poddubny and Nathan Ratliff and Welf Rehberg and Clemens Schwarke and Ritvik Singh and James Latham Smith and Bingjie Tang and Ruchik Thaker and Matthew Trepte and Karl Van Wyk and Fangzhou Yu and Alex Millane and Vikram Ramasamy and Remo Steiner and Sangeeta Subramanian and Clemens Volk and CY Chen and Neel Jawale and Ashwin Varghese Kuruttukulam and Michael A. Lin and Ajay Mandlekar and Karsten Patzwaldt and John Welsh and Huihua Zhao and Fatima Anes and Jean-Francois Lafleche and Nicolas Moënne-Loccoz and Soowan Park and Rob Stepinski and Dirk Van Gelder and Chris Amevor and Jan Carius and Junyung Chang and Anka He Chen and Pablo de Heras Ciechomski and Gilles Daviet and Mohammad Mohajerani and Julia von Muralt and Viktor Reutsky and Michael Sauter and Simon Schirm and Eric L. Shi and Pierre Terdiman and Kenny Vilella and Tobias Widmer and Gordon Yeoman and Tiffany Chen and Sergey Grizan and Cathy Li and Lotus Li and Connor Smith and Rafael Wiltz and Kostas Alexis and Yan Chang and David Chu and Linxi ”Jim” Fan and Farbod Farshidian and Ankur Handa and Spencer Huang and Marco Hutter and Yashraj Narang and Soha Pouya and Shiwei Sheng and Yuke Zhu and Miles Macklin and Adam Moravanszky and Philipp Reist and Yunrong Guo and David Hoeller and Gavriel State. Isaac Lab: A GPU-Accelerated Simulation Framework for Multi-Modal Robot Learning. *arXiv preprint arXiv:2511.04831*, 2025. (Accessed on 01/03/2026).

- [10] The robocup japanese regional committee — ロボカップとは. <https://www.robocup.or.jp/robocup/>. (Accessed on 12/29/2022).




- [11] Tomoaki Yoshida, Kiyoshi Irie, Yoshitaka Hara, Taro Suzuki, and Masahiro Tomono. Improving stair climbing and slow walking performance in quadrupedal robot gait control using blind policies. In *Proceedings of the 2025 JSME Conference on Robotics and Mechatronics (ROBOMECH 2025)*, No. 2A2-C08, pp. 2A2–C08, Yamagata, Japan, June 2025.










付録







本付録では、本論文の実験において得られた歩行動作の時系列データを記録したグラフを記載する。他は載せきれていません↓にデータはあります https://drive.google.com/drive/folders/1cLqWSd5YyQSVBBJg8vCJhD_Xbf23-j23?usp=sharing










.1 Flat 環境










.1.1 track_lin_vel_xy_exp
































































- .1.2 feet_air_time
- .1.3 dof_pos_limits
- .1.4 joint_deviation_hip
- .1.5 lin_vel_z_l2
- .1.6 dof_acc_l2
- .1.7 dof_torques_l2
- .1.8 feet_slide

謝辞

本研究を進めるにあたり， 1 年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします。