

修士論文

深層強化学習を用いたヒューマノイドロボットの 歩行動作に対する報酬関数の影響分析

Analysis of the effects of reward functions on the walking behavior
of a humanoid robot using deep reinforcement learning

2026 年 3 月 提出

指導教員 林原 靖男 教授

千葉工業大学大学院 先進工学研究科 未来ロボティクス専攻

24S1011 小川晴生

概要

深層強化学習を用いたヒューマノイドロボットの歩行動作に対する報酬関数の影響分析

近年、ヒューマノイドロボットの制御手法として深層強化学習が急速に発展し、複雑な環境への適応が期待されている。しかし、学習の成否を決定づける報酬関数の設計は、設計者の経験則や膨大な試行錯誤に依存しており、個々の報酬項が具体的な歩行動作や物理量に与える因果関係は明確化されていない。本研究では、この課題に対し、報酬関数の各項がロボットの歩行性能および動作生成に及ぼす影響を複数の定量的な評価指標を用いて分析することを目的とする。実験には NVIDIA Isaac Lab 上の Unitree G1 モデルを用い、ベースラインとなる報酬関数から、目標速度追従、遊脚時間、関節トルク抑制といった報酬項の重みを個別に変化させ、その挙動を解析した。評価指標には、歩行速度の追従性、胴体の姿勢偏差、移動に伴う総仕事量などを用いた。実験の結果、速度追従報酬の増加は追従性を向上させる一方で、エネルギー消費の増大や歩行開始時に上体の後傾を招くことがわかった。また、遊脚時間報酬は歩幅や歩行周期に直接的に作用し、関節トルクや角速度への過度なペナルティは動作の凍結や学習の破綻を引き起こす要因となることを確認した。本研究は、各報酬項間に存在するトレードオフ関係を定量的に示し、報酬関数の構成がロボットの歩行動作および性能に及ぼす影響を分析した。

キーワード: 深層強化学習, ヒューマノイドロボット, 報酬関数

abstract

Analysis of the effects of reward functions on the walking
behavior of a humanoid robot using deep reinforcement learning

Deep Reinforcement Learning (DRL) has rapidly evolved as a control strategy for humanoid robots, showing great promise for adaptation to complex environments. However, designing the reward function—a critical factor determining learning success—often relies heavily on heuristics and extensive trial-and-error. Consequently, the causal relationships between individual reward terms and specific physical quantities or locomotion behaviors remain unclear. This study analyzes the impact of individual reward terms on walking performance and motion generation using multiple quantitative evaluation metrics. Experiments were conducted using the Unitree G1 model within the NVIDIA Isaac Lab environment. We analyzed the robot’s behavior by individually varying the weights of specific reward terms—including target velocity tracking, swing time, and joint torque penalties—relative to a baseline. Evaluation metrics included velocity tracking accuracy, torso orientation deviation, and total mechanical work. Results indicated that increasing the velocity tracking reward improved tracking performance but led to higher energy consumption and a backward torso tilt during gait initiation. Furthermore, the swing time reward directly influences step length and gait cycle, whereas excessive penalties on joint torques can cause motion freezing or learning failure. This study quantitatively demonstrates the trade-offs between reward terms and analyzes their impact on humanoid locomotion.

keywords: deep reinforcement learning, humanoid robot, reward function

目次

第 1 章	序論	1
1.1	背景	1
1.2	関連研究	3
1.3	目的	4
1.4	論文構成	4
第 2 章	要素技術	5
2.1	ニューラルネットワーク	5
2.2	強化学習	6
2.3	NVIDIA Isaac Lab	7
2.4	深層強化学習による歩行制御	8
2.5	報酬関数	8
第 3 章	実験環境と方法	9
3.1	実験装置	9
3.2	エージェントと環境モデル	10
3.3	状態・行動空間	11
3.3.1	状態空間	11
3.3.2	行動空間	11
3.3.3	学習におけるランダム要素	11
3.4	報酬関数	12
第 4 章	実験条件と評価指標	15

目次	vi
4.1 実験方法	15
4.2 学習アルゴリズムおよびハイパーパラメータ設定	16
4.3 評価指標	17
4.4 評価シナリオ	18
4.5 標準パラメータによる学習結果	18
4.5.1 歩行速度追従率	19
4.5.2 胴体の姿勢偏差	20
4.5.3 床反力	21
4.5.4 歩幅および左右対称性	22
4.5.5 重心位置と足上げ高さ	24
4.5.6 関節トルクおよび角速度	24
第 5 章 実験結果と考察	27
5.1 Track Lin Vel XY の影響	27
5.2 Feet air time の影響	32
5.3 DOF Joint Limits の影響	36
5.4 Joint Deviation (Hip) の影響	40
5.5 Lin Vel Z L2 の影響	43
5.6 DOF Acc L2 の影響	45
5.7 DOF Torques L2 の影響	50
5.8 Feet Slide の影響	54
5.9 Flat Orientation の影響	59
第 6 章 結論	63
参考文献	65
付録	67
謝辞	68

1.1	Humanoid robots at work	1
2.1	Neural network	5
2.2	Conceptual diagram of reinforcement learning	6
2.3	How nvidia isaac lab works	7
3.1	Track a velocity command on flat terrain with the unitree g1	10
4.1	Walking behavior learned with default parameters	19
4.2	Velocity tracking of walking motion learned with default parameters . .	20
4.3	Stability analysis of walking motion learned with default parameters . .	21
4.4	Ground reaction force of walking motion learned with default parameters	22
4.5	Stride length analysis of walking motion learned with default parameters	23
4.6	2d trajectory of walking motion learned with default parameters	23
4.7	Trajectory side view of walking motion learned with default parameters .	24
4.8	Left foot torque during walking behavior learned with default parameters	25
4.9	Left foot angular velocity during walking behavior learned with default parameter	25
4.10	Maximum, mean, and standard deviation of joint torque per gait cycle with default parameter	26
4.11	Maximum, mean, and standard deviation of joint angular velocity per gait cycle with default parameter	26

5.1	When g1 starts walking, its torso leans back	28
5.2	Velocity tracking performance (reward: Track Lin Vel XY, weight: 1.0) .	29
5.3	Velocity tracking performance (reward: Track Lin Vel XY, weight: 2.0) .	30
5.4	Stability analysis (reward: Track Lin Vel XY, weight: 1.0)	31
5.5	Stability analysis (reward: Track Lin Vel XY, weight: 2.0)	31
5.6	Total energy by Track Lin Vel XY and Feet Air Time parameters	32
5.7	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Air Time, weight: 0.0)	33
5.8	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Air Time, weight: 1.0)	33
5.9	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Air Time, weight: 0.0)	34
5.10	Maximum, mean, and standard deviation of joint angular velocity per gait cycle (reward: Feet Air Time, weight: 1.0)	34
5.11	Side view of walking motion trajectories (reward: Feet Air Time, weight: 1.0)	35
5.12	Ground reaction force of walking gait (reward: Feet Air Time, weight: 1.0)	35
5.13	Ground reaction force of walking gait (reward: DOF Joint Limits, weight: 0.0)	37
5.14	Ground reaction force of walking gait (reward: DOF Joint Limits, weight: -0.6)	37
5.15	Ground reaction force of walking gait (reward: DOF Joint Limits, weight: -1.0)	38
5.16	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Joint Limits, weight: 0.0)	38
5.17	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Joint Limits, weight: -1.0)	39
5.18	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Joint Limits, weight: 0.0)	39

5.19	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Joint Limits, weight: -1.0)	40
5.20	Walking using knees and ankles	41
5.21	Left foot angular velocity of policy trained with (reward: Joint Deviation (Hip), weight: 0.0)	41
5.22	Left foot angular velocity of policy trained with (reward: Joint Deviation (Hip), weight: -1.0)	42
5.23	Stride length analysis (reward: Joint Deviation (Hip), weight: 0.0) . . .	42
5.24	Stride length analysis (reward: Joint Deviation (Hip), weight: -1.0) . . .	43
5.25	Side view of walking motion trajectories (reward: Lin Vel Z L2, weight: 0.0)	44
5.26	Side view of walking motion trajectories (reward: Lin Vel Z L2, weight: 1.0)	44
5.27	Gait learned with a penalty of -5.0×10^{-6}	45
5.28	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: 0.0)	46
5.29	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: -1.0×10^{-7})	46
5.30	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: -5.0×10^{-6})	47
5.31	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: 0.0)	47
5.32	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: -1.0×10^{-7})	48
5.33	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: -5.0×10^{-6})	48
5.34	Total Energy by DOF Acc L2 and DOF Torques parameters	49
5.35	Foot print(reward: DOF Acc L2, weight: -5.0×10^{-6})	49
5.36	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: 0.0)	51

5.37	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-6})	51
5.38	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-5})	52
5.39	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: 0.0)	52
5.40	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-6})	53
5.41	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-5})	53
5.42	Walking with strong impact on the ground	54
5.43	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Slide, weight: 0.0)	55
5.44	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Slide, weight: -1.0)	55
5.45	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Slide, weight: 0.0)	56
5.46	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Slide, weight: -1.0)	56
5.47	Ground reaction force of walking gait (reward: Feet Slide, weight: 0.0) .	57
5.48	Ground reaction force of walking gait (reward: Feet Slide, weight: -1.0) .	57
5.49	Total Energy by DOF Joint Limits and Joint deviation(hip), Lin Vel Z L2, Feet Slide, Flat orientation L2 parameters	58
5.50	Side view of walking motion trajectories (reward: Feet Slide, weight: 1.0)	58
5.51	Walking with torso facing up	59
5.52	Left foot angular velocity of policy trained with (reward: Flat Orientation, weight: 0.0)	60
5.53	Left foot angular velocity of policy trained with (reward: Flat Orientation, weight: -1.0)	60

5.54	Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Flat Orientation, weight: 0.0)	61
5.55	Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Flat Orientation, weight: 0.0)	61
5.56	Stability analysis (reward: Flat Orientation, weight: 0.0)	62
5.57	Stability analysis (reward: Flat Orientation, weight: -1.0)	62

表目次

3.1	Experimental setup	9
3.2	Actuator parameters of the unitree g1 robot model	10
3.3	Reward function parameters for the unitree g1 robot in flat terrain . . .	14
4.1	Hyperparameters for ppo training	17

第 1 章

序論

1.1 背景

近年，少子高齢化に伴う労働人口の減少が深刻化しており，人間に代わる作業の自動化や，災害現場などの危険な環境下での活動手段として，ヒューマノイドロボットへの期待が高まっている．[1], [2] これまでヒューマノイドロボットの歩行制御には，主に物理モデルに基づく制御手法が用いられてきた [3]．しかし，近年では，深層強化学習（Deep Reinforcement Learning: DRL）を用いたアプローチ [4] が急速に発展している．DRL は複雑な環境への複雑な環境への適応能力や，より高度な動作獲得の可能性から，従来の物理モデルでは困難であった多様なタスクへの応用が期待されている．




Fig. 1.1: Humanoid robots at work

この DRL を用いた歩行制御において、学習の成否や獲得される動作の質を決定づける重要な要素が「報酬関数」の設計である。DRL では、ロボット（エージェント）が環境と相互作用し、得られる「報酬」を最大化するように行動を学習する。この際、どのような行動に対して報酬を与えるかを定義する報酬関数は、ロボットの行動指針そのものとなる。

しかし、既存の研究動向を概観すると、学習アルゴリズムやネットワーク構造の提案に主眼が置かれる傾向があり、報酬関数の設計論に関する議論は十分になされていないのが現状である。多くの研究において、報酬関数内の各パラメータは設計者の経験則や膨大な回数の試行錯誤によって決定されている。近年では大規模言語モデル（LLM）等を用いたパラメータ調整の自動化 [5] も試みられているが、最終的に「なぜそのパラメータ設定が良いのか」という因果関係や、各項が歩行性能や動作の質に与えるトレードオフについてはブラックボックス化している側面が否めない。

1.2 関連研究

Van Marum らは、ヒューマノイドロボットの立位および歩行制御において、実世界での性能を定量的に評価、比較するための低コストなベンチマーク手法を提案するとともに、報酬関数の設計を再考し、従来の規定的な報酬に代わる、制約を最小限に留めた報酬関数を構築した。コマンド追従性や外乱回復などの指標を用いた実験により、提案手法が外乱に対して堅牢な制御器の学習を可能にすることを示している。[6]

Peng らは、ヒューマノイドロボットが歩行、走行、ホッピングといった多様な歩容 (Gait) を単一のポリシーで実現するために、歩行周期の位相情報を用いた条件付き強化学習手法を提案している。彼らは、学習の進度に合わせてタスクの難易度を調整するマルチフェーズカリキュラムに加え、Gait Mask と呼ばれる報酬設計手法を導入した。これは、歩行サイクル中の特定の位相 (接地や足の振り出しなど) においてのみ特定の報酬項を有効化あるいは無効化する仕組みである。この動的な報酬設計により、静的な報酬関数では競合しがちな制約を適切に分離し、全方向へのロバストな移動動作の獲得に成功している。[7]

Wu らは、大規模言語モデル (LLM) を用いて報酬関数の設計から学習実行、フィードバックによる最適化までを全自動化するフレームワーク「STRIDE」を提案している。STRIDE では、ロボットの身体構造 (URDF) とタスク記述を LLM に入力することで、Python 形式の報酬関数コードを生成する。さらに、シミュレーションから得られた学習結果 (歩行速度や失敗要因など) をテキスト情報として LLM にフィードバックし、報酬コードの修正と再学習を自律的に繰り返す。比較実験において、STRIDE は従来の手法 (EUREKA など) や人間が設計した報酬関数を上回るパフォーマンスを発揮し、多様な地形でのスプリント動作の獲得に成功している。[5]

このように、報酬設計の自動化やタスクに応じた設計手法の提案がされている。しかし、パラメータ設定の根拠となる因果関係や各報酬項が動作の質に与える影響のトレードオフについては明確になっておらず、依然として設計過程がブラックボックス化している側面が否めない。

1.3 目的

本研究では、深層強化学習を用いたヒューマノイドロボットの歩行動作獲得を対象とし、報酬関数の設計が歩行性能や動作に与える影響を明らかにすることを目的とする。具体的には、報酬関数を構成する各パラメータを複数の設定で変更しながら学習実験を行い、得られた制御則を複数の定量的な指標を用いて評価、分析する。これにより、各報酬項の役割やパラメータ間のトレードオフ関係を明確にする。

1.4 論文構成

本論文の構成を述べる。本論文は、以下の全 6 章で構成されている。第 1 章では、本研究の背景や関連技術、目的を述べる。第 2 章では、本研究に用いた要素技術を述べる。第 3 章では、本研究に用いる学習環境について述べる。第 4 章では、本研究に用いる実験条件と評価指標について述べる。第 5 章では、各パラメータを変更した学習済みモデルの評価と考察について述べる。第 6 章では、結論について述べる。

第2章

要素技術

2.1 ニューラルネットワーク

ニューラルネットワーク (Neural Networks) は、脳の神経回路網を模倣した数理モデルである。入力層、中間層、出力層からなる多層構造を持ち、各層のニューロンが結合荷重（重み）を介して信号を伝播させることで、複雑な非線形関数を近似する能力を有する。学習は、出力と正解値との誤差を最小化するように、誤差逆伝播法を用いて重みを更新することで行われる。




Fig. 2.1: Neural network

2.2 強化学習

強化学習（Reinforcement Learning: RL）は、未知の環境下において、エージェントが試行錯誤を通じて最適な行動方策（Policy）を獲得する機械学習手法である。教師あり学習のように正解データが明示的に与えられるのではなく、エージェント自身の行動結果に対する報酬（Reward）を環境から受け取り、その利益を最大化するように学習が進む点が特徴である。




Fig. 2.2: Conceptual diagram of reinforcement learning

Fig. 2.2 に強化学習におけるエージェントと環境の相互作用の概念図を示す。この枠組みにおいて、学習は離散時間におけるエージェントと環境の相互作用の繰り返しによって進行する。まず、時刻 t において、エージェントは環境の状態 $s_t \in S$ を観測する。次に、エージェントは自身の保持する方策 $\pi(a_t | s_t)$ に基づき、現在の状態 s_t に応じた行動 $a_t \in A$ を決定し、環境に対して実行する。行動 a_t が実行されると、環境は物理法則やタスクのルール（状態遷移確率 $P(s_{t+1} | s_t, a_t)$ ）に従って次の状態 s_{t+1} へと遷移する。この際、その行動および遷移の良し悪しを評価するスカラー値である報酬 r_t が環境からエージェントへとフィードバックされる。エージェントはこの報酬を頼りに、より良い行動を選択できるように自身の方策を更新していく。この一連のプロセスは、一般にマルコフ決定過程（Markov Decision Process: MDP）として定式化され、状態集合 S 、行動集合 A 、遷移確率 P 報酬関数 R 、および割引率 γ の5つ組で定義される。ここでエージェントの目的は、単に目の前の即時報酬 r_t を最大化することではなく、将来にわたって得られる報酬の総和、すなわち割引累積報酬（収益） G_t の期待値を最大化することである。収益 G_t は、割引率 $\gamma \in [0, 1]$ を用いて式 2.1 のように定義

される。

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots \quad (2.1)$$

式 2.1 における割引率 γ は，将来の報酬を現在の価値としてどれだけ割り引くかを決定するパラメータである． γ が 0 に近いほど近視眼的な評価となり，1 に近いほど長期的な利益を重視することになる．強化学習アルゴリズムは，環境との相互作用データの蓄積を通じて，この収益 G_t の期待値を最大化するような最適方策 π^* を探索するものである．

2.3 NVIDIA Isaac Lab

NVIDIA Isaac Lab[8] は，Omniverse 上に構築されたロボット学習用シミュレーションフレームワークである．PhysX による高精度な物理演算と GPU による並列処理を組み合わせることで，数千体のロボットを同時にシミュレーション可能とする．これにより，深層強化学習に不可欠な膨大な試行回数を短時間で確保でき，現実世界では困難な大規模なデータ収集と効率的な学習を実現する．




Fig. 2.3: How nvidia isaac lab works

2.4 深層強化学習による歩行制御

深層強化学習を用いた歩行制御は、試行錯誤を通じてロバストな運動機能を獲得する手法である。Rudin ら [9] は、GPU による大規模並列シミュレーションを活用し、数千体のロボットを同時に学習させることで、不整地踏破可能な制御則を数分で獲得できることを示した。

2.5 報酬関数

報酬関数 (Reward Function) は、強化学習においてエージェントに対し、「何が良い行動か」を定義する重要な要素であり、学習の成否および獲得される動作を決定づける。[10] 一般に、強化学習における報酬関数は単一の指標のみで構成されることは稀であり、複数の相反する目的を調整するために、異なる目的項の加重和として設計される。主に、タスク報酬と正則化項 (ペナルティ) の二つに大別できる。タスク報酬は、エージェントが達成すべき主たる目標を記述した項である。ロボット制御を例にとれば、目標とする速度や位置への追従誤差を最小化することがこれに相当し、エージェントが意図された通りの成果を挙げた際に正の報酬を与えることで、目的の達成を直接的に動機づける。これに対し、正則化項やペナルティは、獲得される行動の質や効率性を担保するための項である。単にタスクを達成するだけでなく、エネルギー消費の最小化や、急激な制御入力 of 抑制などがある。これらは負の報酬としてフィードバックされ、エージェントが無駄な動きや危険な挙動を避けつつ、合理的かつ自然な方策へ収束するように誘導する役割を担っている。

第 3 章

実験環境と方法

本章では，報酬関数の変化が歩行動作へ与える影響を調査するために行う実験について述べる．まず，学習に使用したシミュレータや実験を行う環境モデル，エージェントについて述べる．なお，本実験では NVIDIA Isaac Lab[8] で標準提供されている Unitree G1 の学習環境（locomotion）を用いる．次に，状態，行動空間や報酬関数について述べる．

3.1 実験装置

本実験の環境を表に示す．

Table 3.1: Experimental setup

OS	Ubuntu 22.04
Simulator	NVIDIA Isaac Sim
Framework	NVIDIA Isaac Lab
CPU	Intel [®] Core™ i7-14700
GPU	NVIDIA GeForce RTX 4090 SUPER
RAM	32 GB
Storage	2.0 TB

3.2 エージェントと環境モデル

本研究では，エージェントとして NVIDIA Isaac Lab にて標準提供されている Unitree G1 のロボットモデルを使用する．また，実験を行う環境モデルについては，Fig. 3.1 に示す平地環境を用いる．初期姿勢においては，ロボットのベース（骨盤）の高さは 0.74 [m] に設定されている．ロボットの初期の関節角度は，直立姿勢を基準に定義されており，Hip Pitch 関節は -0.20 [rad]，Knee 関節は 0.42 [rad]，Ankle Pitch 関節は -0.23 [rad] に設定されている．




Fig. 3.1: Track a velocity command on flat terrain with the unitree g1

Table 3.2: Actuator parameters of the unitree g1 robot model

Joint Name	Max Trq. [Nm]	Max Vel. [rad/s]	Stiffness (K_p)	Damping (K_d)
Hip (Yaw, Roll)	300.0	23.0	150.0	5.0
Hip (Pitch), Knee, Torso	300.0	23.0	200.0	5.0
Ankle (Pitch, Roll)	20.0	9.0	20.0	2.0
Arms (Shoulder, Elbow, Wrist)	300.0	23.0	40.0	10.0

3.3 状態・行動空間

3.3.1 状態空間

エージェントが各時刻 t において環境から受け取る観測ベクトル $\mathbf{o}_t$ は、ロボットの固有受容感覚および外部計測情報により構成される。

- **ベースリンク情報:** ベースの角速度, および重力ベクトルの射影 (姿勢情報)
- **コマンド:** 目標とする並進速度 (v_x^{cmd}, v_y^{cmd}) および旋回角速度 (ω_z^{cmd})
- **関節情報:** 各関節の角度位置 q_t および角速度 $\dot{q}_t$
- **履歴情報:** 直前の行動 $\mathbf{a}_{t-1}$

3.3.2 行動空間

行動空間 $\mathcal{A}$ は、ロボットの各関節に対する目標角度司令で構成される連続空間である。制御周期ごとに、ポリシーネットワークから出力された行動は、初期姿勢からの相対的な変位として解釈され、スケール係数 (0.5) が乗じられた後、デフォルトの関節角度に加算される。最終的なトルク司令は、P ゲイン (剛性) K_p および D ゲイン (減衰) K_d を用いた PD 制御則により算出される。

$$\tau = K_p(q_{target} - q) - K_d\dot{q} \quad (3.1)$$

ここで、 q および $\dot{q}$ は現在の関節角度および角速度である。

3.3.3 学習におけるランダム要素

シミュレーション環境と実環境の差異 (Reality Gap) を埋め、ロバストな方策を獲得するために、学習時には以下のドメインランダム化 (Domain Randomization) を適用する。

- **初期状態のランダム化:** エピソード開始時において、ロボットのベース位置, 向き, および関節角度にノイズを加えることで、特定の初期状態への過学習を防ぐ。
- **物理パラメータの摂動:** リンクの質量や重心位置, 地面との摩擦係数などを一定の範囲

内でランダムに変動させ、物理モデルの不確かさに対する頑健性を向上させる。

3.4 報酬関数

本研究では、目標速度への追従を目的とした正の報酬と、エネルギー効率や安定性を阻害する動作に対する負の報酬の加重和として、以下の報酬 r_t が定義されている。

$$r_t = \sum_i \omega_i \cdot r_{i,t} \quad (3.2)$$

ここで、 ω_i は各報酬項の重み係数、 $r_{i,t}$ は時刻 t における各報酬項の値を示す。

- **Termination penalty**(終了ペナルティ)：エピソードが早期に終了した場合に与えられる大きな負の報酬である。これにより、エージェントは可能な限り転倒を避ける動作を促す。

$$r_{\text{term}} = \begin{cases} -200.0 & \text{if terminated} \\ 0 & \text{otherwise} \end{cases} \quad (3.3)$$

- **Track Lin Vel XY**：ロボット座標系における XY 平面の並進速度 v_{xy} と目標速度 $v_{\text{cmd},xy}$ の誤差に基づく。

$$r_{\text{lin_vel}} = \exp\left(-\frac{\|\mathbf{v}_{\text{cmd},xy} - \mathbf{v}_{xy}\|^2}{\sigma_{\text{lin}}^2}\right) \quad (3.4)$$

ここで、 σ_{lin} はカーネル幅を決定するスケーリングパラメータである。このパラメータは、目標値との誤差に対する報酬の減衰率を制御する役割を持つ。 σ が小さいほど関数は鋭くなり、わずかな誤差でも報酬が大きく減少するため、より厳密な追従が要求される。逆に σ が大きいほど関数は緩やかになり、ある程度の誤差が許容されるようになる。本実験では、初期学習の安定性と最終的な追従精度のバランスを考慮し、 $\sigma_{\text{lin}} = 0.5$ に設定されている。

- **Track Ang Vel Z**：ワールド座標系における Z 軸周りの ω_z と目標角速度 $\omega_{\text{cmd},z}$ の誤差に基づく。

$$r_{\text{ang_vel}} = \exp\left(-\frac{(\omega_{\text{cmd},z} - \omega_z)^2}{\sigma_{\text{ang}}^2}\right) \quad (3.5)$$

ここで、 σ_{ang} も同様に報酬の感度を調整するスケーリングパラメータであり、本実験では $\sigma_{\text{ang}} = 0.5$ を用いた。

- **Feet Air Time**(遊脚時間報酬)：二足歩行ロボット特有の交互な足運びを学習するため、片足支持状態における遊脚時間を報酬として与える.

$$r_{\text{air_time}} = \sum_{\text{foot}} \mathbb{I}_{\text{single_stance}} \cdot \min(t_{\text{air, foot}}, \theta_{\text{threshold}}) \quad (3.6)$$

ここで、 $t_{\text{air, foot}}$ は各足が滞空している時間、 $\theta_{\text{threshold}} = 0.4[s]$ は上限閾値である.

- **Lin Vel Z L2**：歩行中の上下動を抑制する.

$$r_{\text{lin_vel_z}} = -v_z^2 \quad (3.7)$$

- **Action Rate L2**：急激な制御入力の変化を抑える.

$$r_{\text{action_rate}} = -\|\mathbf{a}_t - \mathbf{a}_{t-1}\|^2 \quad (3.8)$$

- **DOF Acc L2**：関節加速度 $\ddot{\mathbf{q}}$ の大きさを抑制する.

$$r_{\text{dof_acc}} = -\|\ddot{\mathbf{q}}\|^2 \quad (3.9)$$

本環境では、Hip, Knee に対して適用される.

- **DOF Torques L2**：関節トルク $\boldsymbol{\tau}$ の大きさを抑制する.

$$r_{\text{dof_torques}} = -\|\boldsymbol{\tau}\|^2 \quad (3.10)$$

本環境では、Hip, Knee に対して適用される.

- **Feet Slide**：接地している足の水平速度 $v_{\text{foot}, xy}$ に対するペナルティを与え、地面に滑ることを防ぐ.

$$r_{\text{slide}} = -\sum_{\text{foot}} \mathbb{I}_{\text{contact}} \cdot \|\mathbf{v}_{\text{foot}, xy}\| \quad (3.11)$$

- **Joint Deviation(Hip)**：特定の関節が、初期姿勢から大きく逸脱することを防ぎ、不自然な脚の開閉を抑制する.

$$r_{\text{joint_deviation}} = -\sum_{j \in \mathcal{J}_{\text{target}}} |q_j - q_j^{\text{default}}| \quad (3.12)$$

- **Flat Orientation**：ロボットの体幹 (Base Link) が地面に対して水平であることを促す.

$$r_{\text{flat_orientation}} = -\|\mathbf{g}_{xy}^{\text{robot}}\|^2 \quad (3.13)$$

- **DOF Joint Limits**(関節可動域ペナルティ)：各関節が可動域限界に近づきすぎることを防ぐ.

$$r_{\text{limits}} = - \sum_j (\max(0, q_j - q_j^{\max} + \epsilon) + \max(0, q_j^{\min} - q_j + \epsilon)) \quad (3.14)$$

本環境では, Ankle に対して適用される.

また, $\mathbf{v}_{\text{cmd},xy}$ は目標並進速度, $\mathbf{v}_{xy}$ は現在の並進速度, $\omega_{\text{cmd},z}$ は目標旋回角速度, ω_z は現在の旋回角速度である. また, $\mathbf{a}_t$ は時刻 t における行動 (目標関節角度変位), $\ddot{\mathbf{q}}$ は関節角加速度, $\boldsymbol{\tau}$ は関節トルクを表す. 本実験の平地環境における各報酬項の重み係数 ω_i の設定値を表 3.3 に示す. 本設定は, NVIDIA Isaac Lab にて標準提供されている Unitree G1 の学習用パラメータと同一である.

Table 3.3: Reward function parameters for the unitree g1 robot in flat terrain

Reward term	Weight
Track Lin Vel XY	1.0
Track Ang Vel Z	1.0
Feet Air Time	0.75
Lin Vel Z L2	-0.2
Action Rate L2	-0.005
DOF Acc L2	-1.0×10^{-7}
DOF Torques L2	-2.0×10^{-6}
DOF Joint Limits	-1.0
Feet Slide	-0.1
Joint deviation(hip)	-0.1
Flat orientation	-1.0
Termination penalty	-200

第 4 章

実験条件と評価指標

本章では，前章で述べた報酬関数の各構成要素が，獲得される歩行動作にどのような影響を与えるかを検証するために行う実験条件と評価指標について述べる．

4.1 実験方法

本研究では，第 3 章で定義した報酬関数を構成する各項が，ヒューマノイドロボットの歩行動作獲得にどのような影響を与えるかを調査する．報酬関数に含まれる各項の重み係数 ω_i は，学習される動作の特性を決定づける重要なハイパーパラメータである．本実験では，Table 3.3 に示した標準のパラメータ設定を基準とし，調査対象とする特定の報酬項の重みのみを個別に変化させながら学習を行うことで，その項が歩行挙動に与える影響を分離して評価する．調査対象とする報酬項およびそのパラメータ（重み）は以下の通りである．なお，負の報酬については，0(無効化) から過剰な抑制まで段階的に値を変化させている．

- Track Lin Vel XY : 目標並進速度への追従 [0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 5.0] (**default: 1.0**)
- Feet Air Time : 遊脚時間の確保 [0.0, 0.1, 0.2, 0.4, 0.6, 0.8, 1.0] (**default: 0.75**)
- DOF Joint Limits(Anlke) : 関節可動域制限の遵守 [0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0] (**default: -1.0**)
- Joint Deviation(Hip) : 股関節の初期位置からの逸脱抑制 [0.0, -0.1, -0.25, -0.5, -0.75, -1.0] (**default: -0.1**)

- Lin Vel Z L2 : 重心上下動 (Z 軸速度) の抑制 $[0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]$
(default: **-0.2**)
- DOF Acc L2(Hip, Knee) : 関節加速度の抑制 $[0.0, -1.0 \times 10^{-5}, -1.0 \times 10^{-6}, -5.0 \times 10^{-6}, -1.0 \times 10^{-7}, -2.5 \times 10^{-7}, -5.0 \times 10^{-7}, -7.5 \times 10^{-7}, -1.0 \times 10^{-8}, -5.0 \times 10^{-8}]$
(default: -1.0×10^{-7})
- DOF Torques L2(Hip, Knee) : 関節トルクの抑制 $[0.0, -2.0 \times 10^{-7}, -5.0 \times 10^{-7}, -1.0 \times 10^{-6}, -2.0 \times 10^{-6}, -5.0 \times 10^{-6}, -1.0 \times 10^{-5}]$ (default: -2.0×10^{-6})
- Feet Slide : 接地時の滑り抑制 $[0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]$ (default: **-0.1**)
- Flat Orientation : 胴体の水平維持を促す $[0.0, -0.1, -0.2, -0.4, -0.6, -0.8, -1.0]$
(default: **-1.0**)

4.2 学習アルゴリズムおよびハイパーパラメータ設定

本研究では、深層強化学習アルゴリズムとして Proximal Policy Optimization (PPO) [11] を採用した。学習環境は NVIDIA Isaac Lab[8] フレームワーク上に構築されており、シミュレーションは 4,096 個の並列環境で実行される仕様となっている。方策 (Actor) および価値関数 (Critic) のネットワーク構造は、共に 3 層の隠れ層を持つ多層パーセプトロン (MLP) で構成されている。各隠れ層のユニット数は入力側から順に $[256, 128, 128]$ となっており、活性化関数には ELU (Exponential Linear Unit) を使用する。学習設定として、最大イテレーション数は 1,500 回、各イテレーションにおける 1 環境あたりのステップ数は 24 ステップとする。これにより、学習全体での総サンプル数は約 1.47×10^8 ステップとなる。本実験で使ったハイパーパラメータの設定を Table 4.1 に示す。

Table 4.1: Hyperparameters for ppo training

Parameter	Value
Algorithm	PPO
Number of Environments	4,096
Max Iterations	1,500
Steps per Env per Iteration	24
Hidden Layers (Actor/Critic)	[256, 128, 128]
Activation Function	ELU
Optimizer	Adam
Learning Rate	1.0×10^{-3} (Adaptive)
Mini-batches	4
Num Learning Epochs	5
Discount Factor (γ)	0.99
GAE Parameter (λ)	0.95
Clip Parameter (ϵ)	0.2
Entropy Coefficient	0.008

4.3 評価指標

学習された歩行方策の性能を多角的に検証するため，先行研究 [6][7][12] のベンチマーク手法を参考に，運動性能，動作安定性，およびエネルギー効率の観点から以下の7つの指標を選定した．

- 歩行速度追従率

ロボットが目標とする指令速度通りに移動できているかを評価する最も基本的な指標である．目標速度 $\mathbf{v}_{cmd}$ と実際のベースリンク速度 $\mathbf{v}_{real}$ を比較，計測する．

- 胴体の姿勢偏差

歩行中のベースリンク（体幹）の姿勢安定性を評価する指標である．重力ベクトルに対

するロール・ピッチ角の傾き，および目標ヨー角からの偏差を計測する．

- 床反力

接地時の衝撃および左右の荷重移動の滑らかさを評価する指標である．足裏にかかる垂直反力 (F_z) のピーク値や変動を確認し，過度な衝撃が発生していないかを検証する．

- 歩幅および左右対称性

左右の足の着地位置 (Y 軸方向の距離) を計測する．左右の歩幅が均等であるか対称性も併せて確認し，安定した歩容が形成されているかを判断する．

- 重心位置と足上げ高さ

ロボット全体の重心 (CoM) の軌跡と，遊脚中の足先高さを計測する．

- 関節トルクおよび角速度

各関節の出力トルク τ および角速度 $\dot{q}$ の時系列データを計測する．また，1 歩行周期における各値の最大値，平均値，標準偏差を計測する．

- 総仕事量

評価区間 (Flat 環境: 10 m) を走行するのに要した機械的仕事量の総和である．van Marum ら [6] を参考に各関節の出力トルクと角速度の積の総和．

4.4 評価シナリオ

上記の指標を計測するため，学習済みモデルを用いて Fig. 3.1 と同等の環境条件で歩行実験を行う．評価区間はスタート地点から 10 m とし，ゴールまでの歩行データを計測する．目標前進速度は $1.0[m/s]$ に固定する．ただし，評価開始から 20 秒以上，スタートから左右 3m 以上離れた場合はその時点で終了とする．

4.5 標準パラメータによる学習結果

本節では，前節で定めた評価指標に基づき，標準パラメータ (Table 3.3) を用いて学習を行った結果について述べる．学習済み方策による歩行動作の様子を Fig. 4.1 に示す．以下，4.3 節で挙げた各評価指標順に，計測された時系列データについて解説する．




Fig. 4.1: Walking behavior learned with default parameters

4.5.1 歩行速度追従率

ロボットの目標速度に対する追従性能を Fig. 4.2 に示す．グラフの横軸は経過時間 $[s]$ を表しており，縦軸は上から順にベースリンクの並進速度 X （進行方向），側方速度（ Y ），およびヨー角速度（ Z ）を示している．グラフ最上段の並進速度 X の推移に着目すると，歩行開始から約 2 秒間の加速区間を経て，その後は目標速度である $1.0 [m/s]$ 付近で安定して推移していることが確認できる．また，側方速度（ Y ）およびヨー角速度（ Z ）は共に 0 付近を維持しており，蛇行や回転を伴わない直進歩行を示している．




Fig. 4.2: Velocity tracking of walking motion learned with default parameters

4.5.2 胴体の姿勢偏差

歩行中の姿勢安定の状態を Fig. 4.3 に示す．横軸は経過時間 [s]，縦軸はベースリンクのロール角 (Roll) およびピッチ角 (Pitch) を表す．ロール角，ピッチ角ともに歩行周期（足の踏み替え）に同期した周期的な振動波形を示している．その振幅は一定範囲内に収束しており，時間経過に伴う発散や，特定方向への恒常的な傾きは見られないことから，安定した姿勢が維持されている．




Fig. 4.3: Stability analysis of walking motion learned with default parameters

4.5.3 床反力

足の接地状態を示す床反力（垂直成分）の推移を Fig. 4.4 に示す．横軸は経過時間 [s]，縦軸は左右の接地のタイミングを視覚的に分離するため，便宜上，右足（Right Foot）の値を負として表す．グラフより，左右の脚が交互に接地と離地を繰り返し接地時のピーク値が確認できる．




Fig. 4.4: Ground reaction force of walking motion learned with default parameters

4.5.4 歩幅および左右対称性

歩容の対称性および着地位置の正確性を検証した結果を Fig. 4.5 に、2次元平面上の足跡を Fig. 4.6 および Fig. 4.5 に示す。Fig. 4.5 において、歩行開始直後の加速期を除き、歩幅は一定値に収束しており、左右脚で均等なストライドが刻まれている。また、Fig. 4.6 の足跡プロット (Footprint) においても、Y 軸方向 (左右) へのばらつきが小さく、X 軸に沿って直線的な歩行軌道が形成されていることがわかる。ただし、本研究で扱っている方策は速度追従を目的としているため、位置ずれに対する補正機能 (位置決め制御) は有していない。




Fig. 4.5: Stride length analysis of walking motion learned with default parameters




Fig. 4.6: 2d trajectory of walking motion learned with default parameters

4.5.5 重心位置と足上げ高さ

ロボットの側面軌跡（Side view trajectory）を Fig. 4.7 に示す．横軸はロボットの進行方向の位置 (X)，縦軸は高さ (Z) を表している．足先軌跡（赤と青の点線）に着目すると，遊脚期において地面 ($Z = 0$) から一定の高さを保った放物線軌道を描いている．これは，路面との接触（つまずき）を回避し，円滑な遊脚動作が行われていることを示唆している．また，黒線の重心位置も一定の高さを維持して歩行していることがわかる．




Fig. 4.7: Trajectory side view of walking motion learned with default parameters

4.5.6 関節トルクおよび角速度

各関節の駆動状況を示す時系列データを Fig. 4.8, 4.9 に示す．横軸は経過時間 [s] を表しており，縦軸は各関節の出力トルク [Nm] および角速度 [rad/s] を示している．また，Fig. 4.10, 4.11 は1歩行周期あたりの各関節のトルクおよび角速度の最大値，平均値，標準偏差を表すグラフである．最大値は赤印，平均値は棒グラフ，標準偏差はエラーバーでそれぞれ表している．



Fig. 4.8: Left foot torque during walking behavior learned with default parameters




Fig. 4.9: Left foot angular velocity during walking behavior learned with default parameter




Fig. 4.10: Maximum, mean, and standard deviation of joint torque per gait cycle with default parameter




Fig. 4.11: Maximum, mean, and standard deviation of joint angular velocity per gait cycle with default parameter

第 5 章

実験結果と考察

5.1 Track Lin Vel XY の影響

本節では、**Track Lin Vel XY**（目標並進速度への追従報酬）の重みを [0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 5.0] のように変化させた場合の影響について述べる．Fig. 5.2～5.5 は、Track Lin Vel XY の重みを 1.0 および 2.0 とした際の速度追従率と胴体の姿勢偏差を示したものである．まず、重みの値が大きくなるにつれて目標速度への追従性が向上し、歩行開始時に急激に $1.0 [m/s]$ へ到達しようとする傾向が見られた．その結果、ロボットの上半身が後方へ大きく傾く挙動（Fig. 5.1, 後傾）が確認された．また、Fig. 5.6 より、速度追従の優先度が高まる（重みが増加する）ほど、総仕事量が増加する傾向も確認された．これは目標並進速度への追従を最優先した結果、ロボットの姿勢を水平維持する報酬である **Flat Orientation** や、関節トルクおよび角速度の抑制（**DOF Torques L2**, **DOF Acc L2**）を促す報酬項の影響が相対的に低下したためである．本来、人間が急加速を行う場合、加速に伴う慣性モーメントを打ち消し、効率的に推進力を得るためには、重心を進行方向へ傾ける前傾姿勢をとることが力学的に合理的である．しかし、本実験で確認された後傾しながらの加速は、速度追従の重みが支配的になりすぎたことで、エージェントが姿勢安定のための予備動作（前傾）に時間を費やすよりも、大きなトルクを発揮して脚部を先行させ、即時的に目標速度誤差を最小化することを優先した結果であると解釈できる．すなわち、エネルギー効率や姿勢安定性を犠牲にしても、慣性による上体の遅れを許容する近視眼的な方策が学習されたことを示唆している．




Fig. 5.1: When g1 starts walking, its torso leans back




Fig. 5.2: Velocity tracking performance (reward: Track Lin Vel XY, weight: 1.0)




Fig. 5.3: Velocity tracking performance (reward: Track Lin Vel XY, weight: 2.0)




Fig. 5.4: Stability analysis (reward: Track Lin Vel XY, weight: 1.0)




Fig. 5.5: Stability analysis (reward: Track Lin Vel XY, weight: 2.0)




Fig. 5.6: Total energy by Track Lin Vel XY and Feet Air Time parameters

5.2 Feet air time の影響

本節では、**Feet air time**（遊脚時間の確保）の重みを $[0.0, 0.1, 0.2, 0.4, 0.6, 0.8, 1.0]$ のように変化させた場合の影響について述べる。Fig. 5.7～5.10 は、**Feet air time** を 0.0 および 1.0 とした際の 1 歩行周期あたりの各関節のトルクおよび角速度の最大値，平均値，標準偏差を表すグラフを示したグラフである。また、**Feet air time** を 1.0 の場合の Fig. 5.11 は重心位置と足上げ高さ，Fig. 5.12 は床反力を示したものである。

実験の結果、重みの増加に伴い歩行周期が長くなり、歩幅が 0.3 [m] から 0.5 [m] へと増大する傾向が確認された。遊脚時間を長く確保するためには、足をより高く持ち上げるか、あるいは滞空時間を稼ぐために一步の移動距離（ストライド）を伸ばす必要がある。本実験においては、同時に関節トルクを抑制する報酬（**DOF Torques L2**）が設定されている。そのため、大きなトルクを要する足上げ動作を行うよりも、慣性を利用して歩幅を広げる戦略の方がエネルギー効率の観点で有利となり、学習器がこの歩容を選択したと推測される。また、重みが 1.0 の場合において、左右の遊脚時で歩行の対称性が崩れる現象が確認された。これは、**Feet air time** 報酬が過大になったことで、関節の初期位置からの逸脱抑制する報酬である **Joint Deviation** との競合が発生し、安定限界付近まで滞空時間を延ばそうする局所解に陥ったこ

とが原因であると考えられる。なお、歩幅の増大に伴い通常懸念される関節トルクや角速度の顕著な増加は確認されなかった。これは、前述の通り歩行周期が長くなったこと、すなわち動作全体が緩やかになったことで、急激な加減速に伴う慣性力が抑制されたためであると解釈できる。




Fig. 5.7: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Air Time, weight: 0.0)




Fig. 5.8: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Air Time, weight: 1.0)




Fig. 5.9: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Air Time, weight: 0.0)




Fig. 5.10: Maximum, mean, and standard deviation of joint angular velocity per gait cycle (reward: Feet Air Time, weight: 1.0)




Fig. 5.11: Side view of walking motion trajectories (reward: Feet Air Time, weight: 1.0)




Fig. 5.12: Ground reaction force of walking gait (reward: Feet Air Time, weight: 1.0)

5.3 DOF Joint Limits の影響

本節では、**DOF Joint Limits**（関節可動域制限に対するペナルティ，対象：Ankle）の重みを $[0.0, -0.1, \dots, -1.0]$ のように変化させた場合の影響について述べる．Fig. 5.13～5.15 は重みを 0.0（無効化），-0.6，-1.0（最大）にした際の床反力，Fig. 5.16, 5.17 は重みを 0.0, -1.0 とした際の 1 歩行周期における各関節のトルク，Fig. 5.18, 5.19 は同様に各関節の角速度の最大値，平均値，標準偏差を示したものである．実験の結果，ペナルティの重みが増加するにつれて，Ankle_Joint のトルクおよび角速度が顕著に減少する傾向が確認された．これは，学習器が可動域制限のペナルティを回避するために，足首関節の駆動を最小限に抑える歩行を獲得した結果である．一方で，床反力の推移を確認すると，重みの増加に伴い着地時のピーク値が増大していることがわかる．物理的な観点から考察すると，通常，足首関節は着地時において受動的なコンプライアンス（柔軟性）を発揮し，地面からの衝撃を吸収するダンパーの役割を担う．しかし，本設定では可動域制限が厳しく課されたことで，ロボットは足首を硬く固定するような動作を余儀なくされた．その結果，着地衝撃を関節の動きで逃がすことができず，運動エネルギーが直接的に高い床反力として現れたと考えられる．このことから，関節保護を目的とした過度な可動域制限は，衝撃吸収能力の欠如を招き，かえって機体への衝撃負荷を高めるトレードオフの関係にあることが示唆された．




Fig. 5.13: Ground reaction force of walking gait (reward: DOF Joint Limits, weight: 0.0)




Fig. 5.14: Ground reaction force of walking gait (reward: DOF Joint Limits, weight: -0.6)




Fig. 5.15: Ground reaction force of walking gait (reward: DOF Joint Limits, weight: -1.0)




Fig. 5.16: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Joint Limits, weight: 0.0)




Fig. 5.17: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Joint Limits, weight: -1.0)




Fig. 5.18: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Joint Limits, weight: 0.0)




Fig. 5.19: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Joint Limits, weight: -1.0)

5.4 Joint Deviation (Hip) の影響

本節では、**Joint Deviation (Hip)**（股関節の初期位置からの逸脱に対するペナルティ）重みを $[0.0, -0.1, \dots, -1.0]$ のように変化させた場合の影響について述べる。Fig. 5.21～Fig. 5.24 は、**Joint Deviation (Hip)** の重みを $0.0, -1.0$ と設定した際の、左足の関節角速度および歩幅（ストライド）の推移を示したものである。実験の結果、ペナルティの重み（絶対値）が増加するに伴い、Hip joint（股関節）の角速度および可動範囲が顕著に抑制される傾向が確認された。これに伴い、ロボットは Hip の運動不足分を Knee（膝）や Ankle（足首）の駆動によって補う、いわゆる代償動作を用いて歩行を継続する様子が見られた（Fig. 5.20）。物理的な観点から考察すると、脚移動において股関節は脚全体の振り出し（スイング動作）の起点となるため、この可動域制限は脚先軌道の振幅、すなわち歩幅の物理的な縮小に直結する。本実験では、股関節の制限により歩幅が強制的に減少したため、目標速度を維持するために歩行周波数を増大させる歩行がとられたと解釈できる。その結果として、観測されたような歩行周期の短縮および、小刻みな歩行動作が生成されたと考えられる。




Fig. 5.20: Walking using knees and ankles




Fig. 5.21: Left foot angular velocity of policy trained with (reward: Joint Deviation (Hip), weight: 0.0)




Fig. 5.22: Left foot angular velocity of policy trained with (reward: Joint Deviation (Hip), weight: -1.0)




Fig. 5.23: Stride length analysis (reward: Joint Deviation (Hip), weight: 0.0)




Fig. 5.24: Stride length analysis (reward: Joint Deviation (Hip), weight: -1.0)

5.5 Lin Vel Z L2 の影響

本節では、**Lin Vel Z L2**（重心鉛直速度に対するペナルティ）の重みを $[0.0, -0.1, \dots, -1.0]$ のように変化させた場合の影響について述べる。Fig. 5.25, 5.26 は重みを 0.0, -1.0 にした際の重心位置と足上げ高さを示したものである。実験の結果、ペナルティの重みが増加するにつれて、重心軌跡の上下動が抑制されていることが確認された。また、この重心の平坦化に伴い、遊脚時の高さを低く保つ歩容が獲得された。物理的な観点から考察すると、通常の歩行動作は倒立振子のように重心の位置エネルギーと運動エネルギーを交換しながら進むため、必然的に重心の上下動を伴う。しかし、本設定では鉛直速度 v_z に強いペナルティが課されたため、学習器は重心高さを一定に保つ行動を強いられた。重心を上下させずに足を前に運ぶためには、床面を蹴って体を持ち上げる動作を排除する必要がある。その結果、ロボットは鉛直方向への運動量変化を最小限に抑えるために、足を高く上げることを放棄し、地面すれすれを移動させる「すり足」に近い歩容を選択したと解釈できる。なお、この歩容の変化に関わらず、本実験で用いた他の評価指標（エネルギー効率や転倒率など）においては統計的に有意な悪化は見られなかった。これは、平坦な環境においては、必ずしも足を高く上げることが歩行の必須条件ではなく、重心を安定させるこの戦略が局所的な最適解として機能したためと考えられる。




Fig. 5.25: Side view of walking motion trajectories (reward: Lin Vel Z L2, weight: 0.0)




Fig. 5.26: Side view of walking motion trajectories (reward: Lin Vel Z L2, weight: 1.0)

5.6 DOF Acc L2 の影響

本節では、**DOF Acc L2**（関節加速度に対するペナルティ，対象：Hip, Knee）の重みを $[0.0, -1.0 \times 10^{-7}, -5.0 \times 10^{-6}]$ のように変化させた場合の影響について述べる．以下の Fig. 5.28～5.30, Fig. 5.31～5.33 は $[0.0, -1.0 \times 10^{-7}, -5.0 \times 10^{-6}]$ とした際の1歩行周期における各関節のトルクと角速度の最大値，平均値，標準偏差を示したものである．Fig. 5.34 は **DOF Acc L2** の重みを変化ごとの総仕事量，Fig. 5.35 は重みを -5.0×10^{-6} の場合の歩行の軌跡を示す．実験の結果，ペナルティの重みが増加するにつれて，Hip_pitch および Knee_pitch の角速度が抑制され，動作が平滑化される傾向が確認された．これに伴い，Fig. 5.34 に示すように歩行時の総仕事量は減少した．物理的な観点から考察すると，関節加速度の抑制は，急激な加減速動作の排除を意味する．運動方程式 $F = ma$ （回転系では $\tau = I\alpha$ ）に従えば，加速度（ α ）の低減は動作に必要な慣性力を小さく抑えることにつながるため，結果としてアクチュエータが発揮すべきトルクおよび消費エネルギーが低減されたと解釈できる．しかしながら，重みを -5.0×10^{-6} まで強めた設定では，直進性が損なわれ，経路が大きく湾曲する挙動が確認された．これは，加速度への過度なペナルティが，歩行の安定化に必要な角速度を阻害したためと考えられる．直進を維持する角速度が足りず，方位誤差が累積し湾曲に至ったと推測される．なお，さらに重みを大きくした -5.0×10^{-5} の設定では，ロボットは動作を停止した．これは，動作すること自体のコスト（**DOF Acc L2**）が，移動によって得られる報酬（速度追従報酬）を上回ったため，学習器が動かないという行動を最適解として選択した結果である．




Fig. 5.27: Gait learned with a penalty of -5.0×10^{-6}




Fig. 5.28: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: 0.0)




Fig. 5.29: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: -1.0×10^{-7})




Fig. 5.30: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Acc L2, weight: -5.0×10^{-6})




Fig. 5.31: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: 0.0)




Fig. 5.32: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: -1.0×10^{-7})




Fig. 5.33: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Acc L2, weight: -5.0×10^{-6})





Fig. 5.34: Total Energy by DOF Acc L2 and DOF Torques parameters

Fig. 5.35: Foot print(reward: DOF Acc L2, weight: -5.0×10^{-6})

5.7 DOF Torques L2 の影響

本節では、**DOF Torques L2**（関節トルクに対するペナルティ，対象：Hip, Knee）の重みを $[0.0, -1.0 \times 10^{-6}, -1.0 \times 10^{-5}]$ のように変化させた場合の影響について述べる．以下の Fig. 5.36～5.38, Fig. 5.39～5.41 は $[0.0, -1.0 \times 10^{-6}, -1.0 \times 10^{-5}]$ とした際の 1 歩行周期における各関節のトルクと角速度の最大値，平均値，標準偏差を示したものである．実験結果として，重みの増加に伴い関節トルクおよび総仕事量の減少傾向が確認された．しかし，前節の **DOF Acc L2**（加速度ペナルティ）による変化と比較すると，その減少幅は限定的であった．物理的な観点から考察すると，関節トルクには運動を生み出すトルク（動的成分）と自重を支えるトルク（静的成分）の二つの役割がある．加速度は等速運動を行うことでゼロに近づけることが可能だが，トルクに関しては，ロボットが転倒せずに姿勢を維持する限り，重力に抗するためのベースライン（重力補償トルク）が物理的な下限値として存在する．そのため，学習器がどれほど効率化を図ろうとも，このベースラインを下回ることはできず，結果として総仕事量に現れる変化が **DOF Acc L2** の場合よりも小さくなったと解釈できる．なお，重みを -2.0×10^{-5} まで強めた設定では，学習が破綻する現象が確認された．これは，ペナルティが過大になり，自重を支えるために最低限必要なトルクさえも許容されなくなったためである．その結果，学習器にとって歩行して報酬を得るメリットよりも，脱力してペナルティを回避する（転倒する）メリットが上回り，歩行動作の獲得に至らなかったと考えられる．




Fig. 5.36: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: 0.0)




Fig. 5.37: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-6})




Fig. 5.38: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-5})




Fig. 5.39: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: 0.0)




Fig. 5.40: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-6})




Fig. 5.41: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: DOF Torques L2, weight: -1.0×10^{-5})

5.8 Feet Slide の影響

本節では、**Feet Slide**（接地時の足の滑りに対するペナルティ）の重みを $[0.0, -1.0]$ と変化した際の影響について述べる．Fig. 5.43 および Fig. 5.44 は、各重み設定における左足の関節トルクの最大値、平均値、標準偏差を、Fig. 5.45 および Fig. 5.46 は角速度を示したものである．また、Fig. 5.47 および Fig. 5.48 に床反力の推移を、Fig. 5.49 に重みごとの総仕事量の変化を示す．なお、Fig. 5.42 は重みが増える場合に観察された特徴的な着地挙動を示したものである．実験の結果、ペナルティの重みが増加するにつれて、Knee_pitch のトルクと角速度に顕著な増加傾向が確認された．歩容に関しては、ペナルティが大きくなるほど地面を強く叩きつけるような挙動へと変化し、これに伴い Fig. 5.49 に示す通り総仕事量が増加した．物理的な観点から考察すると、足先が地面で滑らない条件は、接地点におけるせん断力が最大静止摩擦力よりも小さいこと ($F \leq \mu N$) である．ここで μ は摩擦係数、 N は垂直抗力である．学習器は滑り（せん断方向の移動）を厳しく制限されたため、滑りが発生するリスクを回避するために、着地速度を上げて垂直抗力 N を瞬発的に増大させる行動をとったと考えられる．すなわち、地面を強く踏みつけ、摩擦力の許容限界を引き上げることで滑りを物理的に阻止しようとした結果、関節負荷とエネルギー消費が増大する歩容が形成されたと解釈できる．




Fig. 5.42: Walking with strong impact on the ground




Fig. 5.43: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Slide, weight: 0.0)




Fig. 5.44: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Feet Slide, weight: -1.0)




Fig. 5.45: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Slide, weight: 0.0)




Fig. 5.46: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Feet Slide, weight: -1.0)




Fig. 5.47: Ground reaction force of walking gait (reward: Feet Slide, weight: 0.0)




Fig. 5.48: Ground reaction force of walking gait (reward: Feet Slide, weight: -1.0)




Fig. 5.49: Total Energy by DOF Joint Limits and Joint deviation(hip), Lin Vel Z L2, Feet Slide, Flat orientation L2 parameters




Fig. 5.50: Side view of walking motion trajectories (reward: Feet Slide, weight: 1.0)

5.9 Flat Orientation の影響

本節は、**Flat orientation**(胴体の水平維持を促すペナルティ)の重みを $[0.0, -0.1, \dots, -1.0]$ のように変化させた場合の影響について述べる. Fig. 5.52, 5.52 は重みを 0.0 と -1.0 の左足トルクの時系列データであり, Fig. 5.54, 5.55 重みが 0 とした際の 1 歩行周期における各関節のトルク, 角速度の最大値, 平均値, 標準偏差を示したものである. Fig. 5.56, 5.57 は重みを 0.0 と -1.0 の胴体の姿勢偏差を示したものである. 実験結果より, ペナルティが 0.0 (無効) の場合, ロボットは胴体を大きく後傾させて歩行しており, その姿勢を維持するために Hip_roll (股関節のロール軸) のトルクが増加したことがわかる. 実際にペナルティなしで歩行した際の様子を Fig. 5.51 に示す. 一方, ペナルティの重みが増加した場合は, 胴体の姿勢偏差が低減されていることが確認できる. 胴体が後傾した姿勢では, 上半身の重心位置が股関節の直上から大きく外れることになる. これにより, 重力に起因する回転モーメントが常に発生し続けるため, ロボットはその姿勢を保持するために無駄な抗力 (保持トルク) を出し続けなければならない. 特に Hip_roll のトルク増加は, 後傾姿勢によって左右のバランス保持が困難になり, 体幹の側方安定性を確保するために過剰な制御入力が必要となった結果であると解釈できる. すなわち, **Flat orientation** ペナルティは, 単に姿勢を良くするだけでなく, 重心を支持脚の直上に配置させることで, 姿勢維持に必要な無効トルクを削減する物理的な効果を持っているといえる.




Fig. 5.51: Walking with torso facing up




Fig. 5.52: Left foot angular velocity of policy trained with (reward: Flat Orientation, weight: 0.0)



Fig. 5.53: Left foot angular velocity of policy trained with (reward: Flat Orientation, weight: -1.0)




Fig. 5.54: Maximum, mean, and standard deviation of joint torques per gait cycle (reward: Flat Orientation, weight: 0.0)




Fig. 5.55: Maximum, mean, and standard deviation of joint angular velocities per gait cycle (reward: Flat Orientation, weight: 0.0)




Fig. 5.56: Stability analysis (reward: Flat Orientation, weight: 0.0)




Fig. 5.57: Stability analysis (reward: Flat Orientation, weight: -1.0)

第 6 章

結論

本研究では、深層強化学習を用いたヒューマノイドロボットの歩行制御において、報酬関数の設計が獲得される歩行動作や物理量に与える影響を定量的かつ定性的に分析した。Unitree G1 モデルを用いたシミュレーション実験を通じ、速度追従、遊脚時間、関節制限、姿勢安定化などの代表的な報酬項の重みを個別に変化させることで、学習される方策の変化とその物理的な因果関係を明らかにした。本研究により得られた最も重要な知見は、報酬関数の数値的な最適化と、ロボットの力学的合理性や動作の安全性との間に複雑なトレードオフが存在するということである。

まず、目標速度への追従を最優先した場合、エージェントは将来的な姿勢安定性よりも、直近の速度誤差を最小化することを優先し、上体を後傾させながら脚部を先行させる近視眼的な加速戦略を獲得することが確認された。これは数学的な報酬最大化の観点からは正しい解であっても、実際のロボット運用においては転倒リスクやエネルギー効率の悪化を招く挙動であり、単一の報酬項への過度な重み付けが意図しない歩容を誘発することを示している。また、特定の物理現象を抑制しようとするペナルティ項が、物理法則を介して別のパラメータに悪影響を及ぼす現象も確認された。具体的には、接地時の滑りを抑制する報酬項を強化した結果、ロボットは地面を強く踏みつけて垂直抗力を増大させ、摩擦力の許容限界を引き上げることで滑りを物理的に阻止する「踏みつけ歩行」を獲得した。同様に、関節可動域を厳しく制限した場合には、着地時の衝撃吸収機能が失われ、床反力のピーク値が増大する結果となった。これらは、設計者が意図した「滑りの抑制」や「関節の保護」という目的が、結果として「衝撃負荷の増大」という別の物理的な問題を招く可能性を示唆しており、報酬設計において物理的な連

成効果を考慮することの重要性を浮き彫りにした。エネルギー効率の観点においては、関節トルクそのものを抑制するよりも、関節加速度を抑制する方が総仕事量の低減に有効であることが明らかとなった。関節トルクには自重を支えるための物理的な下限値が存在するのに対し、加速度の抑制は動作の急激な変化（ジャーク）を排除し、慣性力を低減させることで、結果として滑らかで効率的な歩行に直結するためである。一方で、姿勢を水平に保つ報酬は、単に見栄えの良い姿勢を作るだけでなく、重心を支持脚の直上に維持することで、姿勢保持に必要な無駄なトルクを削減する物理的な効果を持つことも確認された。

以上の結果から、ヒューマノイドロボットの強化学習においては、単純に学習の収束を目指すだけでなく、各報酬項が物理的な挙動に及ぼす副作用や、報酬項同士の競合関係を深く理解した上で設計を行う必要があると結論付けられる。本研究において、報酬項と物理現象の因果関係を体系的に整理したことは、従来の試行錯誤に依存した報酬調整から脱却し、より効率的かつ安全な制御方策を獲得するための明確な指針を与えるものである。

参考文献

- [1] Agility Robotics. Agility robotics. <https://www.agilityrobotics.com/>, 2026. (Accessed on 01/03/2026).
- [2] Boston Dynamics. Atlas — boston dynamics. <https://bostondynamics.com/atlas/>, 2026. (Accessed on 01/03/2026).
- [3] Zhaoyuan Gu, Junheng Li, Wenlan Shen, Wenhao Yu, Zhaoming Xie, Stephen McCrory, Xianyi Cheng, Abdulaziz Shamsah, Robert Griffin, C. Karen Liu, Abderahmane Kheddar, Xue Bin Peng, Yuke Zhu, Guanya Shi, Quan Nguyen, Gordon Cheng, Huijun Gao, and Ye Zhao. Humanoid locomotion and manipulation: Current progress and challenges in control, planning, and learning, 2025.
- [4] Lingfan Bao, Josephine N. Humphreys, Tianhu Peng, and Chengxu Zhou. Deep reinforcement learning for bipedal locomotion: A brief survey, 2024.
- [5] Zhenwei Wu, Jinxiong Lu, Yuxiao Chen, Yunxin Liu, Yueting Zhuang, and Luhui Hu. Stride: Automating reward design, deep reinforcement learning training and feedback optimization in humanoid robotics locomotion, 2025.
- [6] Bart van Marum, Aayam Shrestha, Helei Duan, Pranay Dugar, Jeremy Dao, and Alan Fern. Revisiting reward design and evaluation for robust humanoid standing and walking, 2024. IROS 2024.
- [7] Tianhu Peng, Lingfan Bao, and Chengxu Zhou. Gait-conditioned reinforcement learning with multi-phase curriculum for humanoid locomotion, 2025.
- [8] Mayank Mittal, Pascal Roth, et al. Isaac Lab: A GPU-Accelerated Simulation Framework for Multi-Modal Robot Learning. *arXiv preprint arXiv:2511.04831*, 2025. (Accessed on 01/03/2026).

- [9] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning, 2021.
- [10] Adam Laud and Gerald DeJong. The influence of reward on the speed of reinforcement learning: An analysis of shaping. In *Proceedings of the 20th International Conference on Machine Learning (ICML 2003)*, pp. 440–447, 2003.
- [11] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms, 2017.
- [12] Tomoaki Yoshida, Kiyoshi Irie, Yoshitaka Hara, Taro Suzuki, and Masahiro Tomono. Improving stair climbing and slow walking performance in quadrupedal robot gait control using blind policies. In *Proceedings of the 2025 JSME Conference on Robotics and Mechatronics (ROBOMECH 2025)*, No. 2A2-C08, pp. 2A2–C08, Yamagata, Japan, June 2025.

付録

本付録では，本論文の実験において得られた学習済みモデル，および各評価指標における歩行動作のデータをまとめたグラフを記載する．なお，全データは以下の URL から参照可能である．

[https://drive.google.com/drive/folders/18e3GYw2nFh781ZD0P5KlywMMe_SIHkqW?
usp=drive_link](https://drive.google.com/drive/folders/18e3GYw2nFh781ZD0P5KlywMMe_SIHkqW?usp=drive_link)

謝辞

本研究を進めるにあたり，学部3年次から修士課程修了までの4年間にわたり，熱心にご指導いただきました林原靖男教授に深く感謝いたします。先生には，研究に関する学術的なご指導のみならず，進路や生活面など多岐にわたりご相談に乗っていただきましたこと，心より御礼申し上げます。

また，同研究グループの井上氏，山崎氏，相場氏，佐藤氏，野口氏をはじめとする研究室の皆様，ならびに卒業された諸先輩方には，在学中，多大なるご協力をいただきました。ここに記して感謝の意を表します。