

修士論文

深層強化学習を用いたヒューマノイドロボットの
歩行動作に対する報酬関数の影響分析

Analysis of the effect of reward functions on the walking behavior of
a humanoid robot using deep reinforcement learning

2025 年 12 月 25 日 提出

指導教員 林原 靖男 教授

千葉工業大学大学院 先進工学研究科 未来ロボティクス専攻

24S1011 小川晴生

概要

タイトル

キーワード:

abstract

title

keywords:

目次

第 1 章	序論	1
1.1	背景	1
1.2	関連研究	2
1.3	目的	2
1.4	論文構成	3
第 2 章	要素技術	4
2.1	ヒューマノイドロボットの歩行制御手法	4
2.2	ニューラルネットワーク	4
2.3	強化学習	6
2.4	NVIDIA Isaac Lab	6
2.5	深層強化学習による歩行制御	6
2.6	報酬関数の設計と自動化	6
第 3 章	実験環境と方法	8
3.1	本章の概要	8
3.2	実験装置	8
3.3	環境モデル	9
3.4	エージェント	9
3.5	学習におけるランダム要素	10
3.6	状態・行動空間	10
3.6.1	観測空間	11

3.6.2	行動空間	11
3.7	報酬関数（報酬項）	11
3.8	評価指標	12
第 4 章	評価指標	13
4.1	本章の概要	13
4.2	評価指標	13
4.3	予備実験	13
第 5 章	予備実験	14
5.1	実験目的	14
5.2	実験環境	14
5.3	実験	14
5.4	実験結果	14
5.5	評価	15
5.6	考察	15
参考文献		16
付録		17
謝辞		18

図目次

1.1	Example	2
2.1	Example	4
2.2	Example of vertical images	5
2.3	Example	5
2.4	Example	6
2.5	Example	6
3.1	Example	9

表目次

3.1	Experimental Setup	8
3.2	Initial posture angle, torque and angular velocity of each joint	10

第 1 章

序論

1.1 背景

一応 gemini でまとめた結果…

近年、少子高齢化に伴う労働人口の減少が深刻化しており、ヒューマノイドロボットには、人間に代わる作業の自動化や、災害現場などの危険な環境下における代替手段としての期待が高まっている。これまでヒューマノイドロボットの歩行制御には、物理モデルに基づく制御手法が多く用いられてきた。しかし近年では、複雑な環境への適応能力や、高度な動作獲得の可能性から、深層強化学習（Deep Reinforcement Learning: DRL）を用いたアプローチが急速に発展している。DRL では、ロボット（エージェント）が環境と相互作用し、得られる「報酬」を最大化するように行動を学習する。この際、どのような行動に対して報酬を与えるかを定義した「報酬関数」の設計が、学習の成否や獲得される動作の質を決定づける重要な要素となる。しかし、既存の研究動向を俯瞰すると、学習アルゴリズムやネットワーク構造の提案に主眼が置かれる傾向があり、報酬関数の設計論に関する議論は十分になされていないのが現状である。多くの研究において、報酬関数内の各パラメータは、設計者の経験則や膨大な回数の試行錯誤（Trial and Error）によって決定されている。近年では大規模言語モデル（LLM）等を用いたパラメータ調整の自動化も試みられているが、最終的に「なぜそのパラメータ設定が良いのか」という因果関係や、各項が歩行性能や動作の質に与えるトレードオフについてはブラックボックス化している側面が否めない。



Fig. 1.1 Example

1.2 関連研究

- Revisiting Reward Design and Evaluation for Robust Humanoid Standing and Walking
- <https://ieeexplore.ieee.org/document/10654466>
- Gait-Conditioned Reinforcement Learning with Multi-Phase Curriculum for Humanoid Locomotion
- <https://arxiv.org/html/2502.04692v3>
- 歩行動作の報酬関数に関する論文に触れる

1.3 目的

本研究は、深層強化学習を用いたヒューマノイドロボットの歩行動作学習を対象とする。本研究は、報酬関数を構成する各パラメータを変更しながら学習を行い、得られた各学習モデルを複数の比較指標によって評価・分析することを通じて、報酬関数のパラメータが学習プロセスや獲得される歩行動作に与える影響を明らかにすることである。

1.4 論文構成

本論文の構成を述べる．本論文は，以下の全 0 章で構成されている．第 1 章では，本研究の背景や関連技術，目的を述べた．第 2 章では，本研究に用いた要素技術を述べる．第 3 章では，本研究に用いる問題設定について説明し，学習に使用するフレームワークを述べる．第 4 章では，本研究の議論にした内容を説明する．第 5 章では，実験をする上での予備実験について述べる．第 6 章では，実験やその結果に対する考察を述べる．第 7 章では，本研究の成果をまとめ，今後の展望について述べる．

第 2 章

要素技術

とりあえず，必要そうな要素を書いて後でまとめる

2.1 ヒューマノイドロボットの歩行制御手法



Fig. 2.1 Example

2.2 ニューラルネットワーク

ニューラルネットワークだけの節を作るのはもったいないため，深層強化学習の中で話した方がよいかもしれない



Fig. 2.2 Example of vertical images



Fig. 2.3 Example

2.3 強化学習

2.4 NVIDIA Isaac Lab

NVIDIA Isaac Lab は,

2.5 深層強化学習による歩行制御



Fig. 2.4 Example

2.6 報酬関数の設計と自動化



Fig. 2.5 Example

報酬関数の全体を離す報酬項の分類本研究における報酬関数は 3 章あたりに記載する

第 3 章

実験環境と方法

3.1 本章の概要

本章では，報酬関数の変化が歩行動作へ与える影響を調査するため，以下の環境と方法で実験を行う．

3.2 実験装置

本実験の環境を表に示す．

Table 3.1 Experimental Setup

OS	Ubuntu 22.04
Simulator	NVIDIA Isaac Sim
Framework	NVIDIA Isaac Lab
CPU	Intel [®] Core™ i7-14700
GPU	NVIDIA GeForce RTX 4090 SUPER
RAM	32 GB
Storage	2.0 TB

3.3 環境モデル

実験を行う環境モデルについて述べる．環境モデルは NVIDIA Isaac Lab にて標準提供されている locomotion（二足歩行ロボットが歩行動作＝タスク）を使用する．本モデルの外観を図 X に示す．下に図を貼る G1 と H1 の環境

3.4 エージェント

本研究では，エージェントとして NVIDIA Isaac Lab [5] にて標準提供されている Unitree G1 のロボットモデルを使用する．本モデルの外観と初期姿勢を図 X に示す．また，初期姿勢における各関節の初期角度，トルク，角速度の仕様一覧を表 Y に示す．



Fig. 3.1 Example

Table 3.2 Initial posture angle, torque and angular velocity of each joint

Joint	Initial attitude angle [rad]	Torque [Nm]	Velocity [rad/s]
Torso	0	88	32
Hip roll	0	88	32
Hip pitch	0	88	32
Hip yaw	0	88	32
Ankle roll	0	40	53
Ankle pitch	0	40	53
Shoulder roll	0	21	53
Shoulder pitch	0	21	53
Shoulder yaw	0	21	53
Elbow roll	0	21	53
Elbow pitch	0	21	53
Hand zero	0	0.7	23
Hand one	0	0.7	23
Hand two	0	0.7	23
Hand three	0	0.7	23
Hand four	0	0.7	23
Hand five	0	0.7	23
Hand six	0	0.7	23

3.5 学習におけるランダム要素

3.6 状態・行動空間

本学習モデルにおける観測空間（状態空間）および行動空間の定義は以下の通りである。

3.6.1 観測空間

- ロボットの位置と線形速度あとで式を書く
- 目標となる線形速度と角速度
- 各関節の速度
- 各足の接触状態
- 周囲環境（不整地環境のみ）ロボットの足元の地形形状を把握するための地形の高さ情報

3.6.2 行動空間

3.7 報酬関数（報酬項）

本研究では，NVIDIA Isaac Lab, locomotion（二足歩行ロボットが歩行動作＝タスク）を用いる．本研究における報酬関数は以下の通りである．

- $R_{termination_penalty}$ ：ロボットが転倒などの致命的な失敗によりエピソードを終了した場合に，学習がそのような状態を避けるよう促すためである．これは，エージェントに対してこの状態に陥ると大きな大きな不利益があることを学習させ，転倒を避ける動作を促す．

$$r_{term} = w_{term} \cdot \mathbb{1}_{terminated} \quad (3.1)$$

ここで， $w_{term} = -200.0$ はペナルティの重み係数であり， $\mathbb{1}_{terminated}$ はエピソードの異常終了を判定する指示関数である．本モデルにおいて，この項はロボットの胴体（torso_link）が地面に接触した瞬間に適用され，エージェントに対して転倒を回避する強力なバイアスを与える役割を果たす．

- $R_{track_lin_vel_xy_exp}$ （XY 線形速度追従）：エージェントのヨー軸（向いている方向）を基準とした XY 平面での線形速度が，目標速度にどれくらい近いかが評価し，誤差が小さいほど高い報酬を与える．誤差の評価には指数カーネル（共分散）が使用される．

$$r_{\text{track_lin}} = \exp\left(-\frac{\|\mathbf{v}_{xy}^{\text{cmd}} - \mathbf{v}_{xy}^{\text{base_yaw}}\|_2^2}{\sigma^2}\right)$$

- $R_{\text{track_ang_vel_z_exp}}$ (Z 軸角速度追従) : エージェントの目標角速度にどれだけ近いかを評価する.

$$r_{\text{track_ang}} = \exp\left(-\frac{(\omega_z^{\text{cmd}} - \omega_z^{\text{world}})^2}{\sigma^2}\right)$$

- $R_{\text{feet_air_time}}$ (足の滞空時間) : 足が地面から離れている時間 (滞空時間) が一定の閾値 () を超えた場合に報酬を与える. これにより, 足を地面に擦るのではなく, 持ち上げて歩行する動作を促す.

$$r_{\text{air_time}} = \max(0, \min(T_{\text{air},L}, T_{\text{air},R}) - T_{\text{thresh}})$$

- $R_{\text{feet_slide}}$ (足の滑りペナルティ) : 足が地面に接地していると判定されている間に, その足がワールド座標系の XY 方向に速度を持つ (=滑っている) ことに対してペナルティを与える.

$$r_{\text{slide}} = \sum_{f \in \{\text{left}, \text{right}\}} \|\mathbf{v}_{xy}^{\text{foot},f}\|_2 \cdot \mathbb{I}(F_{\text{contact},f} > F_{\text{thresh}})$$

- $R_{\text{flat_orientation_l2}}$ (水平姿勢維持ペナルティ) : エージェントの胴体が水平から傾くことに対してペナルティを与える.

$$r_{\text{orientation}} = \|\mathbf{g}_{\text{proj},xy}^{\text{base}}\|_2^2 = (g_x^{\text{base}})^2 + (g_y^{\text{base}})^2$$

- $R_{\text{dof_pos_limits}}$ (関節可動域ペナルティ) : 関節角度が設定された可動域の上限または下限に近づくことに対してペナルティを与える.

- $R_{\text{joint_deviation_...}}$ (デフォルト姿勢からの逸脱ペナルティ) :

- $R_{\text{action_rate_l2}}$:

$$r_{\text{action_rate}} = \|\mathbf{a}_t - \mathbf{a}_{t-1}\|_2^2$$

- $R_{\text{dof_acc_l2}}$:

- $R_{\text{dof_torques_l2}}$:

$$r_{\text{torque}} = \|\boldsymbol{\tau}\|_2^2 = \sum_{j \in \text{joints}} \tau_j^2$$

3.8 評価指標

本研究では, 以下の評価基準に基づいてエージェントの性能を評価し, 分析する.

-

第 4 章

評価指標

4.1 本章の概要

4.2 評価指標

以下の論文を参考に，各報酬関数のパラメータを変更させて実験を行い，歩行動作に与える影響を評価する．以下は，評価指標の一覧である．

-
- 歩行速度
- エピソード継続時間
- エネルギー消費量
- 安定性指標

4.3 予備実験

報酬項の機能が

etc...

第 5 章

予備実験

5.1 実験目的

まず、各報酬関数が要求されている機能が行われているかの確認

5.2 実験環境

5.3 実験

NVIDIA Isaac Lab に提供されている Unitree G1, locomotion の報酬関数を基準として、第 3 章で説明した本研究の対象とした報酬関数の係数を 0 に設定して学習を行い、以下の分析方法を元に

etc...

実験分析方法

5.4 実験結果

本実験で腕や指を対象としない理由

5.5 評価

5.6 考察

etc...

参考文献

- [1] The robocup japanese regional committee — ロボカップとは. <https://www.robocup.or.jp/robocup/>. (Accessed on 12/29/2022).

付録

謝辞

本研究を進めるにあたり， 1 年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします。